

وزارة التعليم العالي والبحث العلمي

جامعة الأندلس الخاصة للعلوم الطبية

كلية الهندسة الطبية

تشخيص سرطان البروستات باستخدام صور المرنان

مشروع تخرج أعد لنيل درجة الاجازة في الهندسة الطبية/

تقديم الطلاب:

زينب حسين مخلوف

باسل محمد قدور

طارق بشار زيفا

إشراف

د. م. محمد داعر

كلمة شكر

قم للمعلم وفه التبجيله كاد المعلم ان يكون رسولا

في ختام دراستنا الجامعية لا يسعنا إلا ان نتوجه بأسمى

كلمات الشكر

إلى الدكتور الفاضل محمد واعر

على كل الجهود التي قدمها في شكل توجيهات

ومعلومات قيمة ساهمت في إثراء موضوع دراستنا في

جميع جوانبها المختلفة.

كل الحب والاحترام والتقدير
لشخصكم الكريم

الإهداء

(وآخر دعواهم أنّ الحمد لله رب العالمين)

لقد كان الطريق طويلاً وصعباً

وكان الحصول على قدر المشقة مهيباً وعظيماً

اللهم إني سعت وإنك احسنت لي الجزاء

تخرجت وما كنت لأفعل لولا ان الله مكّني

فالحمد لله حين البدء وعند الختام

إلى سندي ومسندي في الحياة عندما أضعف.. إلى من أقوى
بوجوده دائماً.... إلى حبي الأول والأخير.. إلى من افتخر بوجوده
واسمه.. إلى عزّي في الحياة.. إلى من قدم لي الحب والأمان والقوة
والراحة في سبيل سعادتي الشخص الذي لن يتكرر

أبي حبيب عمري

إلى جوهرتي الثمينة.. إلى الشمعة التي تنير حياتي.. إلى الحضن
الدافئ الذي ألجأ إليه.. إلى سكينتي ومسكني.. إلى التي بفضل دعائها
أنا هنا.. إلى من تقبلتني في كل عيوي وضعفي.. إلى مصدر سعادتي..
إلى الكتف الذي لا يميل.. إلى من تحلو الحياة بوجودها

أمي حبيبة روحي

إلى ضحكتي في الحياة.. إلى من كبرت على حبهم وحنانهم.. إلى
جناحي اللذان لا أستطيع بدونهما... إلى الحب الصادق وأول

الداعمين في حياتي.. إلى اللتان امسكتا بيدي كل الطريق... إلى كنزي
في الحياة

أخواتي (ألين، سارة)

إلى من اكتملت العائلة بوجودهم وأضافا السعادة وكانا السند
والأخوة

أصهرتي (محسن، محمد)

إلى صاحبة الوجه البشوش والخدود الجميلة... إلى أُملي في
الحياة.. إلى من يزهر قلبي في وجودها.. إلى صديقة أصعب وأحلى
الأوقات.. إلى الشخص الثابت في حياتي.. إلى من شاركني خطوات
حياتي جميعها.. إلى أختي التي جلبتها لي الحياة.. إلى قطعة السكر في
حياتي

ندى

إلى من وقفت في جانبي.. إلى من جمعتني بها أجمل صدفة في
الحياة.. إلى من تقاسمنا فرحنا ودموعنا.. إلى رفيقة دربي.. إلى من
قضيت معها أجمل أيام حياتي.. إلى صاحبة المواقف الجميلة السند
الذي اتكئ عليه عند ضعفي والمكان الذي أذهب إليه في سعادتي

صديقة العمر لى

إلى من لا تكتمل فرحتي ونجاحي بدونها.. إلى صديقة الطفولة..
إلى الأقرب إلى القلب.. إلى من هونت الطريق بكلمة طيبة أو
بموقف.. إلى التي لن تتكرر في الحياة

نورا

إلى من كنا بمثابة الاخوة.. إلى من عليهم اعتمد.. إلى السند في أي وقت

علي، حمزة

إلى من قضيت معهم أجمل أيام حياتي.. إلى أصدقاء هذه الرحلة.. إلى من كان بوجودهم يهون كل شيء رفاق الدرب

يمام، رهف، آلاء

إلى من هونوا مرارة الأيام وتقاسمت معهم أجمل الذكريات وبوجودهم حولي اشعر بالأمان أحاديثنا ونقاشتنا ضحكاتنا محفورة في الذاكرة لن تزول

مهند، علاء، طارق، يعرب، ليث

إلى من كانت أمّاً ثانية لي و حضناً الجأ إليه..

خالتي فاطمة

الإهداء

إلى الجبل الذي يحميني من كل عواصف الحياة... إلى النجم الذي
أضاء دربي... والسند الذي أعطاني القوة لمواصلة السعي نحو
تحقيق أحلامي.

والدي العزيز

إلى الشمس التي تنير دربي... و نبع الحنان والحب الذي غمر
حياتي... والملاذ الآمن الذي ألجأ إليه , لولا دعائي لما وصلت.

أمي الحبيبة

إلى المساند والداعم والكتف الذي أتكئ عليه عندما تقرر الحياة
أن تميل بي.

أخي الغالي

إلى أصدقاء الطفولة ... أخوة الروح الذين قاسموني فرحي وحزني...
و الأشجار الراسخة في دربي , دمت لي نعم الأخوة

أمين , زين , مجد

إلى من تقاسمت معهم اجمل الأيام والذكريات وهونو مرارة الأيام
أبو وردان , زينب , ربيع , رفيق.....

الإهداء

بسم الله الرحمن الرحيم

(وَقُلْ أَعْمَلُوا فَسَيَرَى اللَّهُ عَمَلَكُمْ وَرَسُولُهُ وَالْمُؤْمِنُونَ)

إلى من كلله الله بالهيبة و الوقار... إلى من علمني العطاء دون
انتظار... إلى من أحمل اسمه ب كل افتخار

والدي الغالي

إلى التي بذلت كل غالي ونفيس من أجلي ... إلى من هي سر
الوجود ... إلى من كان دعائها سر نجاحي

أمي الغالية

إلى عائلتي الكريمة التي ساندتني ولا تزال من أخوة و أخوات

إلى إلى قرة عيني من قاسمتني مشقة الطريق نصيبي الأجل في
الدنيا

كنتي ولا تزالين تنيري لي قناديل دروبي و دوما تدفعيني نحو طرق
أفضل و أجمل

زهراء

إلى كل من علمني و أدبني و أحسن إلي

(وَأَخِرُ دَعْوَاهُمْ أَنِ الْحَمْدُ لِلَّهِ رَبِّ الْعَالَمِينَ ...)

رقم الصفحة	الفهرس
V	جدول الأشكال
VIII	الملخص (عربي)
IX	الملخص (انكليزي)
1	1. الفصل الأول الاطار العام للمشروع
1	2-1 أهمية المشروع
2	3-1 هدف المشروع
2	4-1 مشكلة المشروع
2	5-1 تقسيم الأطروحة
3	2.الفصل الثاني الدراسات المرجعية
3	1-2 مقدمة
3	2-2 تحدي pi-cai
6	3-2 دراسات سابقة لتشخيص سرطان البروستات باستخدام النظم الذكية
6	1-3-2 الكشف الشامل عن سرطان البروستات في صور المرنان باستخدام شبكات CNN
8	2-3-2 تطوير الذكاء الاصطناعي للتشخيص الدقيق لسرطان البروستات باستخدام التصوير بالرنين المغناطيسي
10	3-3-2 تصنيف سرطان البروستات من صور الامواج فوق الصوتية والتصوير بالرنين المغناطيسي باستخدام الذكاء الاصطناعي القابل للتفسير القائم على التعلم العميق
11	4-2 دراسات سابقة للنظم الهجينة
11	1-4-2 التشخيص المبكر لصور المرنان لأورام الدماغ باستخدام تقنيات هجينة بين التعلم العميق والتعلم الآلي

13	2-4-2 تصنيف صور الأشعة المقطعية للرئتين باستخدام بنية الشبكة العصبية التلافيفية العميقة ثلاثية الأبعاد الهجينة
14	2-4-3 نظام تشخيص سرطان الثدي باستخدام ناقلات الدعم الهجينة والشبكة العصبية الآلية الاصطناعية
16	3. الفصل الثالث الدراسة النظرية
16	3-1 تعريف البروستات
16	3-2 سرطان البروستات
17	3-3 أعراض سرطان البروستات
19	3-4 أسباب وعوامل خطر سرطان البروستات
20	3-5 مضاعفات سرطان البروستات
21	3-6 تشخيص سرطان البروستات
21	3-6-1 بروتوكول التشخيص
22	3-6-2 أنواع الفحوصات
23	3-7 تصنيف سرطان البروستات
23	3-7-1 تحديد السرطان بمقياس غليسون
24	3-7-2 تحديد السرطان بمقياس PI-RADS v2
28	3-8 علاج سرطان البروستات
28	3-8-1 العلاجات الإشعاعية الخارجية
28	3-8-2 العلاجات الإشعاعية الداخلية
29	3-8-3 المعالجات الهرمونية
29	3-8-4 استئصال غدة البروستات
30	3-8-5 علاجات أخرى
30	3-9 جهاز الرنين المغناطيسي (MRI)
30	3-9-1 مبدأ عمل جهاز الرنين المغناطيسي
30	3-9-2 مكونات جهاز الرنين المغناطيسي

31	3-9-3 الأسس الفيزيائية للتصوير بالرنين المغناطيسي
33	3-9-4 جهاز الرنين المغناطيسي ثنائي المعاملات (bpMRI)
33	3-10 البرامج المستخدمة
33	3-10-1 برنامج ماتلاب Matlab
34	3-10-2 برنامج 3D-slicer
35	3-10-3 برنامج Evorad workstation
36	3-11 الذكاء الاصطناعي
36	3-11-1 تعريف الذكاء الاصطناعي وتطبيقاته
37	3-11-2 دور الذكاء الاصطناعي في الرعاية الصحية
37	3-11-3 التعلم الآلي machine learning
38	3-11-4 التعلم العميق Deep learning
39	3-12 النظم الهجينة Hubird systems
41	4 . الفصل الرابع القسم العملي
41	4-1 مقدمة
41	4-2 مخطط العمل
42	4-3 قاعدة البيانات
43	4-4 معالجة الأولوية للصور
43	4-4-1 تحويل من صيغة MHA الى صيغة DICOM
44	4-4-2 اختيار شرائح الورم من كل حالة
44	4-4-3 تجهيز الصور للتجزئة
45	4-4-4 تجزئة القناع
46	4-4-5 دمج الصور
46	4-5 تجهيز البيانات للتعلم
47	4-6 النظام الهجين

48	1-6-4 مخطط عمل النظام الهجين
48	2-6-4 شبكات التعلم العميق
48	1-2-6-4 شبكة (Res Network)
54	2-2-6-4 شبكة التعلم العميق (Google Network)
57	3-2-6-4 نتائج الاختبار للشبكتين
58	3-6-4 معالجة البيانات التوصيفية
59	4-6-4 شبكات التعلم بالأنحدار
60	1-4-6-4 Regression learner برنامج
61	2-4-6-4 Decision trees أشجار القرار
63	3-4-6-4 آلة دعم المتجهات : support vector machines
64	3-6-4 نتائج النظام الهجين
65	7-4 تشخيص المرض
66	8-4 المقترحات والتوصيات
76	المراجع
69	الملحق A
74	الملحق B
75	الملحق C
76	الملحق D
77	الملحق E

رقم الصفحة	جدول الأشكال
4	الشكل (1-2) في فحص mpMRI لبروستاتا المريض، يتم تسليط الضوء على المنطقة المشتبه في إصابتها بالسرطان (باللون الأحمر) بواسطة نموذج الذكاء الاصطناعي
6	الشكل (2-2) إطار عمل شامل مقترح لحساب اكتشافات مستوى فوكسل لـ csPCa في عينات التحقق من الصحة / الاختبار للبروستات bpMRI
7	الشكل (1-0) (a) T2W، (b) DWI، (c) يقوم ADC بمسح حالة المريض في مجموعة الاختبار الخارجية TS2، متبوعة بخريطة الكشف عن csPCa كما تتبأ كل نظام مرشح.
7	الشكل (2-2) ست حالات مريضة من مجموعة الاختبارات الخارجية TS2 وخرائط اكتشاف csPCa المقابلة لها، كما تتبأ نظام CAD المقترح. تشير الخطوط الصفراء إلى csPCa
9	(2-5) سير عمل مقارن لمناهج الأشعة الكلاسيكية والتعلم العميق للتشخيص الطبي
12	الشكل (2-6) الهيكل العام للجمع بين تقنيات التعلم العميق والآلي
14	الشكل (2-7) بنية شبكتي CNN ثلاثية الأبعاد المقترحتين
16	الشكل (3-1) الأعضاء التناسلية عند الذكور.
17	الشكل (3-2) سرطان البروستات.
18	الشكل (3-3) تشخيص سرطان البروستات.
24	الشكل (3-4) PIRADS v2. ملاحظات: (a) تسعة وثلاثون منطقة من البروستات
25	الشكل (3-5) التحدي المتمثل في تمييز csPCa بسبب عدم تجانسه المورفولوجي
26	الشكل (3-6) فئات التقييم PI-RADS™ v2 (Steiger et al., 2016)
27	الشكل (3-7) مخطط الانسيابي PI-RADS v2.1
32	الشكل (3-8) بروتونات الهيدروجين وكيفية حركتها في المجال المغناطيسي
34	الشكل (3-10) واجهة ماتلاب
35	الشكل (3-11) واجهة 3D-slicer

36	الشكل (3-12) واجهة Evorad
38	الشكل (3-13) صورة توضيحية للتعلم العميق
41	الشكل (4-1) مخطط العمل
43	الشكل (4-2) خوارزمية المعالجة الأولية
43	الشكل (4-3) تطبيق 3D-slicer خلال عملية التحويل
44	الشكل (4-4) الصور قبل المعالجة للحالة رقم (21 وهي سرطانية) الصورة الأولى T2 , الصورة الثانية قناع البروستات, الصورة الثالثة ADC والصورة الرابعة DWI
45	الشكل (4-5) صور تجزئة القناع من اليمين الى اليسار صورة DWI , صورة ADC , صورة T2
46	الشكل (4-6) صورة تطبيق الدمج للصور الثلاث على حالة ورم سرطاني , تظهر اللون الزرقاء مكان الورم السرطاني وباقي المناطق السليمة تتشارك باللون الأحمر
47	الشكل (4-7) قاعدة البيانات بعد المعالجة الأولية للصور وتجهيز البيانات
48	الشكل (4-8) مخطط عمل النظام الهجين
48	الشكل (4-9) عمل طبقة التلافيف في استخلاص المميزات
49	الشكل (4-10) تأثير دالة التنشيط على الشبكة العصبية
50	الشكل (4-11) دالة تنشيط Relu
51	الشكل (4-12) عمل طبقة التسطيح
51	الشكل (4-13) دخل الشبكة
52	الشكل (4-14) من اليمين المسار الأول , ومن اليسار المسار الثاني
53	الشكل (4-15) مسار الخرج النهائي للشبكة
53	الشكل (4-16) منحنى التدريب لشبكة Resnet, يرمز اللون الأزرق الى دقة التدريب ويرمز اللون الأسود الى دقة الاختبار
54	الشكل (4-17) منحنى معدل الخسارة لشبكة Resnet, يرمز اللون الأحمر لمعدل الخسارة في بيانات التدريب ويرمز اللون الأسود الى معدل الخسارة لبيانات الاختبار

54	الشكل (4-18) مدخل شبكة Google net
55	الشكل (4-19) القالب المكرر
55	الشكل (4-20) الخرج
56	الشكل (4-21) منحني التدريب لشبكة Googlenet , يرمز اللون الأزرق الى دقة التدريب ويرمز اللون الأسود الى دقة الاختبار
56	الشكل (4-22) منحنى معدل الخسارة لشبكة Googlenet, يرمز اللون الأحمر لمعدل الخسارة في بيانات التدريب ويرمز اللون الأسود الى معدل الخسارة لبيانات الاختبار
57	الشكل (4-23) مصفوفة تحوي القيم التي تم التنبأ بها من قبل النظام, والقيم الحقيقية
57	الشكل (4-24) مصفوفة الارتباك
59	الشكل (4-25) مصفوفة دخل نظم الأنحدار
60	الشكل (4-26) واجهة تطبيق Regression learner
61	الشكل (4-27) مبدأ عمل شجرة القرار
62	الشكل (4-28) مبدأ عمل اشجار التجميع
63	الشكل (4-29) مبدأ عمل الأشجار المعززة
63	الشكل (4-30) مبدأ عمل SVM
65	الشكل (4-31) الواجهة الرسومية

المخلص

غدة البروستات هي غدة تناسلية ذكرية توجد أسفل البطن وتحيط بالإحليل في مكان خروجه من المثانة. تعمل البروستات على إفراز السائل المنوي بالاشتراك مع غدة كوبر الذي يغذي الحيوانات المنوية.

يعد سرطان البروستاتا (Pca) أحد أكثر أنواع السرطان انتشارا لدى الرجال , حيث يتلقى 1.4 مليون رجل تشخيصا ويموت 300 ألف بسبب سرطان البروستات كل عام في جميع أنحاء العالم

تأتي أهمية أنظمة الكشف المبكر لسرطان البروستات باستخدام التصوير بالرنين المغناطيسي ثنائي المعاملات (bpMRI) من صعوبة اكتشاف المرض في مرحلة المبكرة بسبب انه لا يسبب اي اعراض او عوامل في المراحل المبكرة وقد اوصت به ارشادات الجمعيه الأوروبية لجراحة المسالك البولية (EAU) لعام 2019 وأرشادات المعهد الوطني البريطاني للتميز في الرعاية الصحية (NICE)

نهدف في هذا المشروع الى انشاء نظام تشخيص لحالات سرطان البروستات باستخدام صور المران باستخدام نظام ذكاء صناعي هجين واجراء معالجة للبيانات التوصيفية لتسهيل قراءة الصور لمساعدة الطبيب ودعم القرار الطبي

تم استخدام قاعدة بيانات 404 حالات وتقسيمها لبيانات تدريب واختبار لنظم التعلم العميق ونظم تعلم بالانحدار وبناء الأنظمة والمعالجة باستخدام ماتلاب

تم بناء ست أنظمة هجينة لتشخيص حالات سرطان البروستات , وكانت دقة الأنظمة عالية (جميع الأنظمة دقتها أعلى من 80%) واختيار افضل نظام تشخيص من حيث الدقة (Resnet+Boosted Trees) وتطبيقه ضمن واجهة رسومية للتفاعل مع الطبيب.

الكلمات المفتاحية: التشخيص الآلي , سرطان البروستات , الصور الطبية , التعلم الهجين , الرنين المغناطيسي ثنائي المعاملات , معالجة الصور

ABSTRACT

The prostate gland is a male reproductive gland located in the lower abdomen and surrounds the urethra where it exits the bladder. The prostate secretes semen in conjunction with the Cooper's gland, which nourishes the sperm.

Prostate cancer (Pca) is one of the most common cancers in men, with 1.4 million men receiving a diagnosis and 300,000 dying from prostate cancer each year worldwide

The importance of early detection systems for prostate cancer using binary parameter magnetic resonance imaging (bpMRI) comes from the difficulty of detecting the disease in the early stages because it does not cause any symptoms or factors in the early stages and is recommended by the 2019 European Association of Urology (EAU) guidelines and the UK National Institute for Health and Care Excellence (NICE) guidelines

In this project, we aim to create a diagnostic system for prostate cancer cases using resonator images using a hybrid artificial intelligence system and perform metadata processing to facilitate image reading for physician assistance and medical decision support.

A database of 404 cases was used and partitioned into training and test data for deep learning systems, regression learning systems, systems building and processing using Matlab

Six hybrid systems were built to diagnose prostate cancer cases, and the accuracy of the systems was high (all systems were more than 80% accurate) and the best diagnostic system in terms of accuracy (Resnet+Boosted Trees) was selected, and implement it in a graphical interface to interact with the doctor

Keywords: Automated diagnosis, prostate cancer, medical images, hybrid learning, biparametric MRI, image processing

الفصل الأول

الإطار العام للمشروع

1-1. مقدمة

البروستات هي غدة تناسلية ذكرية توجد أسفل البطن وتحيط بالإحليل في مكان خروجه من المثانة. تعمل البروستات على إفراز السائل المنوي بالاشتراك مع غدة كوبر الذي يغذي الحيوانات المنوية.

سرطان البروستات هو النمو غير المنضبط للخلايا في البروستات، يبدأ السرطان عندما تتغير الخلايا السليمة في البروستات وتتمو بشكل خارج عن السيطرة، مكونة ورمًا، يمكن أن يكون الورم سرطانًا أو حميدًا ، يعد سرطان البروستات (Prostate cancer (PCa) أحد أكثر أنواع السرطان انتشاراً بين الرجال في جميع أنحاء العالم ، حيث أنه في عام 2019 كان أكثر من 45% من جميع الرجال الذين لديهم تاريخ من السرطان في الولايات المتحدة قد عانوا من PCa (Miller et al., 2019) ، وحسب (WHO) يتلقى 1.4 مليون رجل تشخيصاً ويموت 300 ألف بسبب سرطان البروستات كل عام في جميع أنحاء العالم ، مما يجعله السبب الرئيسي للوفاة بالسرطان لدى الرجال.

1-2. أهمية المشروع

أحد التحديات الرئيسية المحيطة بالتشخيص الدقيق لـ PCa هو الطيف الواسع من السلوك السريري. يمكن أن تتراوح بآفات PCa من الأورام الحميدة منخفضة الدرجة التي لا تتطور أبداً إلى مرض مهم سريرياً إلى الأورام الخبيثة شديدة العدوانية والغزو، أي PCa ذات الأهمية السريرية (clinically significant PCa (csPCa)، والتي يمكن أن تتقدم بسرعة نحو ورم خبيث يؤدي إلى الموت. (Johnson et al., 2014).

في الممارسة السريرية، تُستخدم خزعات البروستات لتعيين درجة غليسون (Gleason Score (GS) ومجموعة درجات غليسون (Gleason Grade Group (GGG) تشريحياً لكل آفة كمقياس لعدوانية السرطان (Epstein et al., 2017).

يتم استخدام الموجات فوق الصوتية عبر المستقيم غير المستهدفة (Non-targeted transrectal ultrasound (TRUS)) بشكل عام لتوجيه عمليات استخراج الخزعة، لكنها تظل عرضة بشدة لعدم اكتشاف csPCa والإفراط في تشخيص PCa البطيء. (Verma et al., 2017).

1-3. هدف المشروع

نهدف في هذا المشروع إلى إنشاء نظام تشخيص لحالات سرطان البروستات باستخدام صور المرنان ببناء نظام ذكاء اصطناعي هجين ومعالجة للبيانات التوصيفية لتسهيل قراءة الصورة وتحديد مرحلة المرض لمساعدة الطبيب ولدعم القرار الطبي.

1-4 مشكلة المشروع

إن الأنظمة التي تستخدم حالياً لتشخيص سرطان البروستات لم تعطِ حتى الآن كفاءة عالية في التشخيص، ومن هنا كانت الرغبة في هذا المشروع بالعمل على رفع كفاءة نظام التشخيص والكشف عن طريق اقتراح خوارزميات تعلم جديدة وزيادة دقة التصنيف.

1-5. تقسيم الأطروحة

سيتم العمل في المشروع على مرحلتين؛ هما:

المرحلة الأولى، وتمتد على فترة زمنية تشمل الفصل الدراسي الأول وتتضمن:

- الجزء النظري ذات الصلة بسرطان البروستات من حيث مفهومه وأنواعه، وأنظمة تشخيصه باستخدام الصور الرقمية وغيرها.
- الدراسات السابقة المأخوذة من المقالات والأبحاث المنشورة مؤخراً في مجال تشخيص سرطان البروستات بدءاً من الصور الرقمية وعبر توظيف الشبكات العصبونية.

المرحلة الثاني تمتد خلال فترة الفصل الدراسي الثاني وستتضمن كل ما يتعلق بمشروعنا من الناحية العملية: اساليب العمل ، الخوارزميات الذكية التي سيتم تطبيقها وغيرها، كما سيشمل النتائج التي سيخرج بها المشروع.

الفصل الثاني

الدراسات المرجعية

2-1. مقدمة

لتحسين التشخيص المبكر وعلاج سرطان البروستات، كان الهدف هو تسريع نقل التصوير بالرنين المغناطيسي عالي الجودة من المختبرات إلى المرضى للمساعدة في تحسين التشخيص المبكر لسرطان البروستات المهم سريرياً وتقليل الخزعات غير الضرورية وعلاج الأمراض الحميدة وتحت الإكلينيكية.


2-2 تحدي pi-cai

مهدت خوارزميات الذكاء الاصطناعي الحديثة (artificial intelligence (AI) الطريق لأنظمة الكشف والتشخيص القوية بمساعدة الكمبيوتر (CAD) التي تنافس الأداء البشري في تحليل الصور الطبية (المرجع 7).

تُعد التجارب السريرية المعيار الذهبي لتقييم الأدوية والتدخلات الجديدة بطريقة مضبوطة ومقارنة، وما يعادل تطوير خوارزميات الذكاء الاصطناعي هو المسابقات الدولية أو "التحديات الكبرى". يمكن للتحديات الكبرى أن تعالج نقص الثقة والأدلة العلمية والتحقق الكافي بين حلول الذكاء الاصطناعي، من خلال توفير الوسائل لمقارنة الخوارزميات ببعضها البعض بطريقة خالية من التحيز، باستخدام بيانات التدريب والاختبار المشتركة. (المرجع 9)،

قبل إصدار هذا التحدي، كان المعيار العام الوحيد لاكتشاف/تشخيص csPCa هو تحدي ProstateX، والذي استخدم مجموعة اختبار مكونة من 140 اختبار mpMRI لتقييم ومقارنة خوارزميات الذكاء الاصطناعي. ومع ذلك، فإن حجم العينة الصغير، والتنوع المحدود (جميع الحالات من نفس المركز ومورد التصوير بالرنين المغناطيسي) وتنسيق التقييم الضعيف، مما أدى للحد من القدرة على استخلاص استنتاجات نهائية بشكل موثوق.

يعد (Prostate Imaging: Cancer AI) PI-CAI تحدياً كبيراً جديداً تماماً، مع أكثر من 10000 فحص تصوير بالرنين المغناطيسي للبروستات تم تنسيقه بعناية للتحقق من صحة خوارزميات الذكاء الاصطناعي الحديثة وتقدير أداء أخصائي الأشعة في اكتشاف وتشخيص csPCa. تم إنشاء الجوانب الرئيسية لتصميم الدراسة بالاشتراك مع مجلس استشاري علمي دولي متعدد التخصصات (16 خبيراً في الذكاء الاصطناعي للبروستات والأشعة والمسالك البولية) - لتوحيد الإرشادات الحالية، ولضمان التحقق الهادف من صحة البروستات - الذكاء الاصطناعي نحو الترجمة السريرية (Reinke et al., 2021).



الشكل (1—2) في فحص mpMRI لبروستاتا المريض، يتم تسليط الضوء على المنطقة المشتبه في إصابتها بالسرطان (باللون الأحمر) بواسطة نموذج الذكاء الاصطناعي (Turkbey et al., 2019).

يتكون PI-CAI في المقام الأول من دراستين فرعيتين:

- دراسة الذكاء الاصطناعي (AI Study): مجموعة بيانات مشروحة متعددة المراكز مكونة من 1500 اختبار للتصوير بالرنين المغناطيسي متاحة للجمهور لجميع الفرق المشاركة ومجتمع البحث ككل. يمكن للفرق استخدام مجموعة البيانات هذه لتطوير نماذج الذكاء الاصطناعي، وإرسال خوارزمياتهم المدربة للتقييم. في نهاية مرحلة التطوير المفتوحة هذه، يتم تصنيف جميع الخوارزميات، بناءً على أدائها على مجموعة اختبار مخفية مكونة من 1000 عملية فحص غير مرئية. في مرحلة الاختبار المغلقة، يقوم المنظمون بإعادة تدريب خوارزميات الذكاء

الاصطناعي الخمس الأعلى تصنيفاً باستخدام مجموعة بيانات أكبر مكونة من 9107 عمليات فحص بالرنين المغناطيسي (بما في ذلك عمليات فحص تدريبية إضافية من مجموعة بيانات خاصة). وأخيراً، يتم إعادة تقييم أدائهم على مجموعة الاختبار المخفية (مع تحليلات إحصائية دقيقة).

• دراسة القارئ (Reader Study): يقوم أكثر من 50 متخصصاً عالمياً في أشعة البروستات بإجراء دراسة للقارئ باستخدام مجموعة فرعية مكونة من 400 عملية مسح من مجموعة الاختبار المخفية. وفي كل حالة، يقوم أخصائيو الأشعة بإكمال تقييماتهم على جولتين. مما يتيح إجراء مقارنات بين الذكاء الاصطناعي والممارسة السريرية الحالية (PI-RADS v2.1). بشكل عام، الهدف من هذه الدراسة هو تقدير أداء أخصائي الأشعة المتوسط في اكتشاف وتشخيص csPCa في التصوير بالرنين المغناطيسي.

في النهاية، يهدف PI-CAI إلى قياس أحدث خوارزميات الذكاء الاصطناعي التي تم تطويرها في AI Study، مقابل أخصائيي أشعة البروستات المشاركين في دراسة القارئ - لتقييم الجدوى السريرية لحلول الذكاء الاصطناعي الحديثة للبروستات في اكتشاف وتشخيص csPCa. في التصوير بالرنين المغناطيسي.

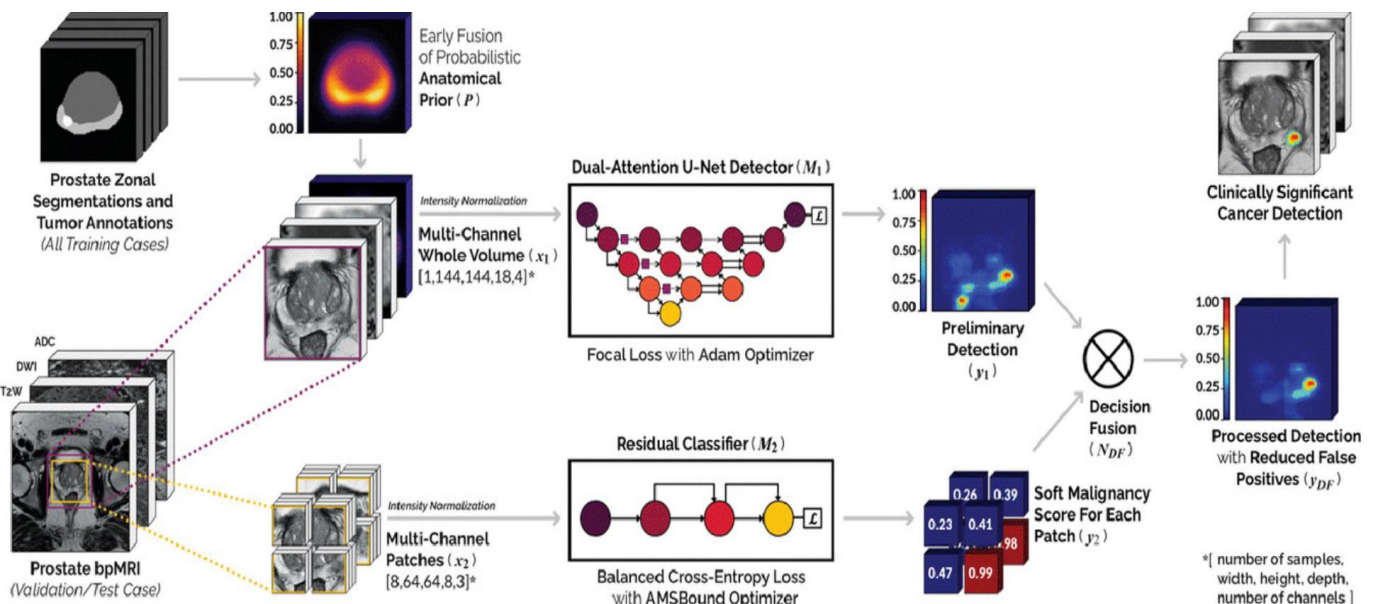
2-3. دراسات سابقة لتشخيص سرطان البروستات باستخدام النظم الذكية

2-3-1. الكشف الشامل عن سرطان البروستات في صور المرنان باستخدام شبكات CNN ثلاثية الأبعاد

End-to end prostate cancer detection in bpMRI via 3D CNNs

قدم الباحث Seha وزملائه عام (2021) نموذج ثلاثي الأبعاد للكشف والتشخيص بمساعدة الكمبيوتر (CAD) متعدد المراحل للتوطين الآلي لسرطان البروستات المهم سريرياً (csPCa) في التصوير بالرنين المغناطيسي ثنائي المعلمات (bpMRI).


تعمل آليات استخراج الميزات على توجيه شبكة الكشف الخاصة بها، واستهداف البنية وأبعاد الميزات شديدة التمييز عبر دقة متعددة. هدفها هو التحديد الدقيق لآفات csPCa الناتجة عن السرطان الخامل ومجموعة واسعة من الأمراض الحميدة التي يمكن أن تصيب غدة البروستات. في الوقت نفسه، يتم استخدام المصنف المتبقي المنفصل لتحقيق تخفيض إيجابي كاذب ثابت، دون فقدان الحساسية العالية أو الكفاءة الحسابية. من أجل توجيه تعميم النموذج بالمعرفة السريرية الخاصة بالمجال، يتم استخدام سابقة تشريحية احتمالية لتفسير الانتشار المكاني والتمييز المنطقي لـ csPCa. باستخدام مجموعة كبيرة من البيانات المكونة من 1950 حالة من جهاز تصوير بالرنين المغناطيسي للبروستات مقترناً بالشرح المقدرة إشعاعياً، يفترض الباحثون أنه يمكن تدريب مثل هذه النماذج المستندة إلى CNN للكشف عن الأورام الخبيثة المؤكدة بالخزعة في مجموعة مستقلة.




الشكل (2—2) إطار عمل شامل مقترح لحساب اكتشافات مستوى فوكسل لـ csPCa في عينات التحقق من الصحة / الاختبار للبروستات bpMRI.

بالنسبة لـ 486 اختبار، حقق نظام التصميم بمساعدة الكمبيوتر ثلاثي الأبعاد 83.69 و 5.22% و 93.19 و 2.96% من حساسية الكشف عند 0.50 و 1.46 إيجابية كاذبة لكل مريض، على التوالي، متفوقاً بشكل كبير على أربعة أحدث البنى الأساسية (Attention U-Net، nnU-Net، UNet++، U-SEResNet) من الأدبيات الحديثة.

بالنسبة لـ 296 عملية فحص خارجية مؤكدة بالخزعة، يشترك نظام CAD المجمع في اتفاق معتدل مع إجماع خبراء الأشعة (76.69%؛ كبا = 0.51، 0.04) وأخصائيي علم الأمراض المستقلين (81.08%؛ كبا = 0.56، 0.06)؛ إظهار تعميم قوي لتشخيص csPCa المؤكد تشريحياً.



الشكل (2—2) (a) T2W، (b) DWI، (c) يقوم ADC بمسح حالة المريض في مجموعة الاختبار الخارجية TS2، متبوعة بخريطة الكشف عن csPCa كما تنبأ كل نظام مرشح.



الشكل (2—3) ست حالات مريضة من مجموعة الاختبارات الخارجية TS2 وخرائط اكتشاف csPCa المقابلة لها، كما تنبأ نظام CAD المقترح. تشير الخطوط الصفراء إلى csPCa

2-3-2 تطوير الذكاء الاصطناعي للتشخيص الدقيق لسرطان البروستاتا باستخدام التصوير بالرنين المغناطيسي


developing artificial intelligence for precision diagnosis of prostate cancer using magnetic resonance imaging

تُعد تطورات الذكاء الاصطناعي ضرورية للنشر الناجح لتشخيص سرطان البروستاتا على مستوى المجتمع بأسره باستخدام التصوير بالرنين المغناطيسي. يجب أن تضمن أنظمة الذكاء الاصطناعي تحقيق الفوائد الرئيسية لتجنب أخذ الخزعة مع الحفاظ على خصوصيات عالية متسقة، في مجموعة من معدلات انتشار المرض. نظرًا لأن جميع أنظمة الذكاء الاصطناعي/أنظمة الكشف الحالية للكشف عن سرطان البروستاتا بمساعدة الحاسوب لا تزال تجريبية، فلا تزال هناك حاجة إلى بذل جهود تطويرية متعددة لتحقيق الرؤية. يجب أن يركز العمل الأولي على تطوير الأنظمة كمساعدات داعمة للتشخيص بحيث يمكن دمج نتائجها في سير عمل أخصائي الأشعة بما في ذلك مهام تحديد الغدة والهدف من أجل الخزعات الاندماجية


ستؤدي إجراءات التشغيل القياسية القوية والقائمة على الذكاء الاصطناعي إلى زيادة ثقة المرضى ، وبالتالي تمكين اعتماد نهج التصوير بالرنين المغناطيسي الموجه لتشخيص سرطان البروستاتا على نطاق أوسع.

تم قبول المسار الموجه بالرنين المغناطيسي من قبل العديد من الإرشادات الوطنية والدولية لتشخيص سرطان البروستاتا. كما اعتمد معيار نظام الإبلاغ عن تصوير البروستاتا وبيانات التصوير بالرنين المغناطيسي متعدد القياسات (PI-RADS) لتقييم التصوير بالرنين المغناطيسي متعدد القياسات (mpMRI) والإبلاغ عنه في العديد من المبادئ التوجيهية للعمل على استخدام الخزعات ونتيجة لذلك، هناك زيادة في الطلب العالمي على التصوير بالرنين المغناطيسي للتشخيص والخزعات الموجهة بالرنين المغناطيسي.

Radiology process



Deep learning process



(2-5) سير عمل مقارنة المناهج الأشعة الكلاسيكية والتعلم العميق للتشخيص الطبي

سير عمل مقارنة المناهج الأشعة الكلاسيكية والتعلم العميق للتشخيص الطبي: سير العمل لعملية الأشعة "الكلاسيكية" (في الأعلى)، وعملية التعلم العميق (في الأسفل). لا يُستخدم سوى عدد قليل من السمات الكمية في التقييمات الإشعاعية التي تستند في الغالب إلى سمات ذاتية مقيمة بصرياً تتضمن القليل من القياسات الكمية مثل الحجم أو قيمة ADC أو وحدة هونسفيلد (HU) أو معدلات/زمن الاسترخاء، بينما لا يعتمد التعلم العميق (وغيره من التقنيات القائمة على الذكاء الاصطناعي) على ميزات محددة مسبقاً، بل يقوم بدلاً من ذلك بإنشاء ميزات مستقلة (حيث تكون الميزات المعقدة عبارة عن تركيبة من ميزات أبسط) داخل الشبكات العصبية الاصطناعية للتمييز بين الفئات المستهدفة المطلوبة. تهدف جميع طرق التحليل في نهاية المطاف إلى توجيه الإدارة السريرية للمرضى المستقبليين الذين لديهم خصائص مماثلة لمجموعات بيانات التعلم والتحقق من الصحة.

اعتبارات عامة لتطورات الذكاء الاصطناعي لتشخيص البروستاتا بالرنين المغناطيسي

- المتطلبات الأساسية لعلوم البيانات

يجب تقييم العديد من القضايا بشكل نقدي لتطورات الذكاء الاصطناعي والتعلم العميق في تشخيص سرطان البروستاتا. من المهم التحقق من وجود نقاط مهمة تقنية وإشعاعية أو سريرية واضحة لتطورات الذكاء الاصطناعي.

- الدقة العلمية

الدقة العلمية ضرورية للتطبيق السريري، بمعنى أنه يجب تقديم وصف لخوارزميات الذكاء الاصطناعي لتمكين إصدار أحكام على صحة التطبيق من حيث السياق، مدعومة بإعدادات وتحليلات تجريبية مناسبة

- تُظهر التجربة أن اكتشاف الكائنات وتصنيفها يحتاج إلى بيانات وفيرة مشروحة بشكل جيد يقدمها الخبراء لتدريب أنظمة التصميم بمساعدة الحاسوب والذكاء الاصطناعي والتحقق من صحة أدائها. يجب ان تتسم مجموعات البيانات عالية الجودة بمجموعات من البيانات التصويرية والبيانات السريرية والبيانات المرضية النسيجية والمتابعة المثالية لتوثيق الحقيقة الأساسية لوجود/عدم وجود سرطان كبير داخل غدة البروستاتا.
- مجموعات البيانات الكبيرة , عادةً ما يتطلب نموذج تعلم عميق واحد يصنف الصور مباشرة كمية كبيرة من البيانات للتدريب.

2-3-3 تصنيف سرطان البروستات من صور الموجات فوق الصوتية والتصوير بالرنين المغناطيسي باستخدام الذكاء الاصطناعي القابل للتفسير القائم على التعلم العميق

Prostate cancer classification from ultrasound and MRI images using deep learning based Explainable Artificial Intelligence

سرطان البروستاتا هو أحد أكثر أشكال السرطان شيوعاً لدى الرجال. ويمكن تعزيز معدل البقاء على قيد الحياة بشكل كبير من خلال الكشف المبكر عن السرطان

اقترح Rafiul_ وزملائه عام (2022) خوارزمية تصنيف آلية جديدة من خلال دمج عدد من مناهج التعلم العميق للكشف عن سرطان البروستاتا من صور الموجات فوق الصوتية وصور التصوير بالرنين المغناطيسي. وبالإضافة إلى ذلك، تشرح الطريقة المقترحة سبب اتخاذ قرار محدد في ضوء مدخلات صورة الامواج فوق الصوتية أو صورة التصوير بالرنين المغناطيسي. تتم إضافة العديد من نماذج التعلّم العميق المُدرّبة مسبقاً والتي تحتوي على طبقات مطوّرة خصيصاً على رأس النماذج المُدرّبة مسبقاً ذات الصلة ويتم تطبيقها على مجموعات البيانات. يولد أفضل نموذج دقة قصوى تبلغ 97% على صور التصوير الامواج فوق الصوتية و80% على صور التصوير بالرنين المغناطيسي لمجموعة الاختبار. تم اختيار النموذج الذي أنتج أفضل أداء في التصنيف لاستخدامه كمستخرج للميزات من مجموعة البيانات لبناء نموذج دمج كخطوة تالية. ولتحسين أداء النماذج، خاصةً على مجموعة بيانات التصوير بالرنين المغناطيسي، تم تطوير نموذج هجين من خلال الجمع بين النموذج الأفضل أداءً الذي تم تدريبه مسبقاً كمستخرج للميزات وبعض خوارزميات التعلم الآلي الأخرى (مثل SVM و Adaboost و K-NN و Random Forests). يعمل نهج الدمج هذا على تحسين أداء النظام بشكل ملحوظ من خلال تحقيق الدقة من 80% إلى 88% على مجموعة بيانات التصوير بالرنين المغناطيسي.

وجدت العديد من الدراسات تطبيق طرق التعلم الآلي لتصنيف نوع السرطان من خلال تحليل بيانات صور الرنين المغناطيسي. ومع ذلك، استخدمت دراسات قليلة جداً تقنية التعلم العميق الحديثة (على سبيل المثال، الشبكة العصبية التلافيفية) لتحليل صور الامواج فوق الصوتية والرنين للكشف عن السرطان المؤيد للحالة. فإن النهج الأكثر شيوعاً هو استخراج الميزات من صورة الإدخال ثم تطبيق نماذج التعلّم الآلي باستخدام الميزات المستخرجة

تعتمد مناهج تحليل السمات التقليدية في الغالب على استخراج السمات من الملمس والكفاف والشدة ومختلف السمات الإحصائية لتطبيقها مع مصنف التعلم الآلي مثل أشجار القرار وآلات دعم المتجهات (SVM) وآدابوست والتعلم العميق للكشف عن السرطان [4]، [5]، [6]. وقد أثبتت مناهج التعلم الآلي العميق بالفعل أنها قابلة للتطبيق في العديد من مجالات تطبيقات معالجة الصور والرؤية الحاسوبية مثل اكتشاف الأجسام، والمراقبة بالفيديو، والمناطق المصابة/المصابة في الصور الطبية

من بين مناهج التعلم العميق الأخرى، تُعد الشبكة العصبية التلافيفية (CNN) أنجح بنية قادرة على استخراج ميزات قوية من الصور المدخلة التي تأخذ في الاعتبار الميزات من المستوى المنخفض إلى المستوى العالي. في خوارزمية CNN النموذجية،

2-4. دراسات سابقة للنظم الهجينة

2-4-1 التشخيص المبكر لصور المرنان لأورام الدماغ باستخدام تقنيات هجينة بين التعلم العميق والتعلم الآلي


Early diagnosis of brain tumor MRI images using hybrid techniques between Deep learning and machine learning

قام الباحث Senan وزملائه عام (2021) بتقييم أداء نماذج التعلم العميق (AlexNet) و (ResNet-18) للتشخيص المبكر لأورام الدماغ. لتقييم أداء تقنيات التعلم العميق (AlexNet و ResNet-18) مع تقنيات التعلم الآلي (آلة ناقلات الدعم (SVM))، و يُطلق عليها اسم AlexNet+SVM و ResNet-18+SVM للكشف المبكر عن أورام الدماغ من صور الرنين المغناطيسي.

في هذه الدراسة، يتم إجراء تجارب مختلفة لتشخيص أورام الدماغ من خلال الجمع بين التعلم العميق وتقنيات التعلم الآلي التقليدية. يتم استخدام تقنية AlexNet و ResNet-18 مع خوارزمية آلة ناقلات الدعم (SVM) لتصنيف وتشخيص أورام الدماغ. يتم تحسين صور التصوير بالرنين المغناطيسي لأورام الدماغ باستخدام تقنية المرشح المتوسط. بعد ذلك، يتم تطبيق تقنيات التعلم العميق لاستخراج ميزات عميقة قوية ومهمة من خلال الطبقات التلافيفية العميقة. تبدأ عملية الجمع بين تقنيات التعلم العميق والتعلم الآلي، حيث يتم استخراج الميزات باستخدام تقنيات التعلم العميق، وهي AlexNet و ResNet-18. ثم يتم تصنيف هذه الميزات باستخدام SoftMax و SVM

يتم استخراج جميع الصور المميزة من خلال الطبقات التلافيفية حيث يتم تطبيق نموذجي AlexNet و ResNet-18 لاستخراج ميزات الشكل واللون والملمس لأورام الدماغ

يتم أيضًا تشخيص جميع الصور باستخدام تقنيات التعلّم العميق لنموذجين، وهما AlexNet و ResNet-18، من خلال SoftMax وباستخدام تقنيات التعلّم الآلي من خلال SVM. يتم تقييم أداء كل مصنف باستخدام مقاييس الدقة والحساسية والخصوصية.



(2-6) الهيكل العام للجمع بين تقنيات التعلّم العميق والآلي

النتيجة:

تم تصنيف الميزات المستخرجة من التعلّم العميق باستخدام SVM والتي تتضمن تجربتين : AlexNet +SVM

و RestNet-18+SVM

في اول تجربة (AlexNet +SVM) كانت الدقة 95.25% والخصوصية 98.50% و كان النموذج قادرا على تشخيص الورم الدبقي بدقة 93.9% والورم السحائي بدقة 93.6% والحالت السليمة بدقة 94.9% والورم الغدي النخامي بدقة 97.8%

اما في التجربة الثانية (RestNet-18+SVM) حقق النموذج دقة بنسبة 91.20% وحساسية بنسبة 91.50% وخصوصية بنسبة 97% كان النموذج قادرا على تشخيص الورم الدبقي بدقة 91.50% والورم السحائي بدقة 86.10% الحالات السليمة بدقة 92.40% والورم الغدي النخامي بدقة 95.60% أظهر النموذج الهجين AlexNet+SVM أفضل أداء من بين النماذج الأخرى. وعلى وجه التحديد، حقق النموذج دقة وحساسية وخصوصية بنسبة 95.1% و95.25% و98.50% على التوالي.

2-4-2 تصنيف صور الأشعة المقطعية للرئتين باستخدام بنية الشبكة العصبية التلافيفية العميقة ثلاثية الأبعاد الهجينة


Classification of pulmonary CT images by using hybrid 3D-Deep learning neural network architecture

يعد استخدام طرق استخراج السمات يدوياً على صور التصوير المقطعي المحوسب عمليات معقدة. وبالتالي، يمكن للتعلم العميق كمجال فعال استخدام طرق الاستخراج التلقائي للميزات كنتيجة يقلل من حجم وزمن عملية استخراج الميزات.

قام الباحث polat وزملائه عام (2019) باقتراح نموذجين يستندان إلى الشبكة العصبية التلافيفية (CNN) كطريقتين للتعلم العميق لتشخيص سرطان الرئة على صور الأشعة المقطعية للرئة. وللتحقق من أداء النموذجين المقترحين (الشبكة العصبية ثلاثية الأبعاد مع softmax التقليدية و الشبكة العصبية ثلاثية الأبعاد الهجينة (3D-CNN) مع دالة الأساس الشعاعي SVM - (RBF))، والمقارنة مع النماذج المعدلة من بنيتين معروفتين للشبكة العصبية التلافيفية (D-3 AlexNet و D-GoogleNet3).

تحتوي الهياكل الرئيسية لكل من بنيتي شبكة CNN ثلاثية الأبعاد المقترحتين، والتي تُستخدم لاستخراج السمات تلقائياً، على ست طبقات تلافيف، وأربع طبقات تجميع كحد أقصى، وطبقتين متصلتين بالكامل. يُعتبر حجم النواة في جميع الطبقات التلافيفية وطبقات التجميع $3 \times 3 \times 3$ و $2 \times 2 \times 2$ على التوالي.

يتم تطبيق دالة التنشيط Relu ذات التكلفة الحسابية الأقل على مخرجات كل طبقة تلافيفية وطبقات متصلة بالكامل. في الطبقة التلافيفية الأولى، يتم تطبيق 96 مرشحاً بحجم مرشح $3 \times 3 \times 3$ على صور المدخلات بحجم 227×227 . تمر خرائط السمات المصغرة عبر الطبقتين التلافيفيتين الثانية والثالثة. يتم تطبيق طبقة التجميع الثانية. بعد ذلك، تُطبّق الطبقات التلافيفية الرابعة والخامسة على خرائط السمات المصغرة. يستمر النموذج ببقية الطبقات حتى يصل للطبقتين المتصلتين بالكامل حيث تكون جميع العصبونات متصلة بجميع العصبونات للطبقة السابقة.



الشكل (2-7) بنية شبكتي CNN ثلاثية الأبعاد المقترحتين

أظهرت النتائج التجريبية أن أداء النموذجين المقترحين تفوق على النموذجين D-AlexNet3 و D-GoogleNet3. علاوة على ذلك، حققت الشبكية ثلاثية الأبعاد الهجينة (3D-CNN) مع SVM نتائج مرضية أكثر

حيث كانت الدقة 91.81% والحساسية 88.53% والدقة على التوالي 91.91%

(91.81% و 88.53% و 91.91% لمعدل الدقة والحساسية والدقة على التوالي) مقارنةً بالشبكة ثلاثية الأبعاد مع softmax في تشخيص سرطان الرئة التي حققت ثاني أعلى معدل دقة 90.23% بينما مع D-Alexnet3 كان معدل الدقة 85.79% و D-GoogleNet3 بمعدل دقة 87.95%

تُظهر النتائج التجريبية أن كلا النموذجين المستقيم والهجين ثلاثي الأبعاد تفوقا على النموذجين الآخرين في تشخيص سرطان الرئة. ومع ذلك، حقق نموذج الشبكة الشبكية ثلاثية الأبعاد الهجينة المقترحة باستخدام SVM القائم على RBF نتائج مهمة: معدل دقة 91.81%، وحساسية 88.53%، وخصوصية 94.23% مقارنةً بالنموذج المستقيم الأبعاد ثلاثي الذي استخدم softmax. وقد ثبت أن مصنف SVM ممتاز لأن يعزز أداء البنية.

2-4-3 نظام تشخيص سرطان الثدي باستخدام ناقلات الدعم الهجينة و الشبكة العصبية الآلية الاصطناعية

Breast cancer diagnosis system using hybrid support vector machine-artificial neural network

قام كل من Sheng وزملائه عام (2020) بتطوير نظام الكشف بمساعدة الحاسوب (CAD) باستخدام التعلم الآلي لأغراض التصنيف. تم العمل على 80 صورة ثدي رقمية للثدي الطبيعي، و 40 صورة ثدي حميدة و 40 صورة ثدي خبيثة. حالات خبيثة من مجموعة بيانات MIAS المصغرة.

تتكون هذه الدراسة من مرحلتين: مرحلة التدريب على البيانات وتطوير نظام CAD للتطبيق الميداني باستخدام MATLAB R2019b.

في مرحلة تدريب البيانات , تمت معالجة الصور أولاً باستخدام مرشح أوسطي لإزالة الضوضاء وتحسينها باستخدام معادلة الرسم البياني. بعد ذلك، تم استخراج ميزات مصفوفة التكرار المشترك للمستوى الرمادي (GLCM) للصور هذه قبل استخدامها في مرحلة تدريب النموذج الصافي.

ثم تم تجزئة 160 صورة ثدي شعاعية للثدي (80 صورة ثدي طبيعية، و40 صورة حميدة و40 صورة خبيثة) تم اختيارها عشوائياً من نظام التصوير الشعاعي المصغر للثدي لتحديد منطقة الاهتمام (ROI).

التصنيف الذي تم إجراؤه على مرحلتين من خلال SVM والثانية هي نموذج الشبكة العصبية الاصطناعية من تطبيق التعرف على أنماط الشبكة العصبية المتوفر في MATLAB R2019b.

فالمرحلة الأولى كانت تصنيف ما إذا كانت صورة الثدي الشعاعية طبيعية أو غير طبيعية. و المرحلة الثانية هي تحديد ما إذا كان الورم حميد أو خبيث. تم إجراء تصنيف SVM عن طريق اختيار كل SVMs لتشغيل النماذج الخطية والتربيعية والتكعيبية الغاوصية الدقيقة الغاوصية المتوسطة والغاوصية الخشنة من SVM في نموذج واحد قصير. ثم تم اختيار افضل نموذج ذو أعلى دقة

وكانت دقة SVM-ANN الهجين عالية تصل ل 99.4% في التفريق بين الحالات الطبيعية والحالات الشاذة والحالات الحميدة والحالات الخبيثة،

. تم اختيار نموذج شبكة SVM-ANN الهجين ليتم استيراده إلى نظام CAD لاختبار البيانات الجديدة نظراً لدقته العالية التي بلغت 99.4% لتصنيف الحالات الطبيعية غير الطبيعية والحالات الحميدة الخبيثة على التوالي. يبدأ نظام يبدأ نظام CAD المطور بوظائف اختيار التصوير الشعاعي للثدي، والتصفية، وإزالة الأجسام غير المرغوب فيها، واستخراج المنطقة الكبيرة، ومنطقة الورم المحتملة، والتجزئة، وضبط تباين الصورة واستخراج الميزات والتصنيف. يمكن لهذا النظام تصنيف صورة الورم إلى طبيعية أو حميدة


الفصل الثالث

الدراسة النظرية

3-1. تعريف البروستات

البروستات هي غدة موجودة بين المثانة والقضيب عند الرجل، ويمر الأنبوب (الإحليل urethra) الذي ينقل البول من المثانة وخارج القضيب مباشرة عبر منتصف البروستات , كما هو مبين في الشكل (3-1).

تنتج البروستات سائلاً يحافظ على صحة النطاف، وهي تنتج تقريباً كل السائل الذي يقذفه الرجل في أثناء الجماع. تكون البروستات بحجم الجوزة في الرجال اليافعين، ولكنها تصبح أكبر مع التقدم في العمر.



الشكل (3-1) الأعضاء التناسلية عند الذكور.


3-2 سرطان البروستات

سرطان البروستات هو السرطان الذي يتكون ويتطور داخل غدة البروستات التي تشبه في شكلها حبة الجوز، وهي المسؤولة عن إنتاج السائل المنوي الذي يغذي وينقل الخلايا المنوية.

سرطان البروستات هو واحد من أكثر السرطانات الشائعة التي تظهر عند الذكور، إن الحصول على نتيجة التشخيص التي تؤكد الإصابة بسرطان غدة البروستات قد يشكل حدثاً مثيراً للخوف والقلق، ليس فقط لأنه مرض يهدد الحياة ولكن أيضاً لأن معالجة سرطان البروستات يمكن أن تؤدي إلى مجموعة متنوعة من الأعراض الجانبية، بما في ذلك مشكلات

كالضعف الجنسي و التحكم بالمثانة، وألم أثناء التبول وتعدد بيلات وذلك بسبب الضغط الحاصل على الأكليل المار من البروستات كما هو مبين في الشكل (2-3). (Litwin & Tan, 2017)

PROSTATE CANCER



الشكل (2-3) سرطان البروستات.

أساليب التشخيص وخيارات العلاج المتاحة في مرض سرطان البروستات تحسنت كثيراً جداً في السنوات الأخيرة، والذي ساعد في ذلك كون سرطان البروستات يبقى محصوراً عادةً في حدود غدة البروستات، وبذلك لا يكون الضرر الحاصل كبيراً وخطيراً.

بينما ينمو بعض أشكال سرطان البروستات بشكل معتدل ويحتاج إلى الحد الأدنى من العلاج فقط أو أنه لا يحتاج إلى علاج البروستات، وفي المقابل هنالك أنواعاً أخرى منه يمكن أن تكون شرسة وتتفشى بسرعة.


إذا تم اكتشاف سرطان البروستات في المراحل المبكرة من المرض عندما يكون لا يزال محصوراً في حدود غدة البروستات فإن فرص الحصول على العلاج الذي من شأنه التغلب على مرض سرطان البروستات تكون أكبر (Litwin & Tan, 2017).

3-3. أعراض سرطان البروستات

في مراحله الأولى لا يكون سرطان البروستات مصحوباً عادةً بأية أعراض جانبية يمكن تمييزها وملاحظتها، كثيرة جداً هي الحالات التي لا يتم فيها تشخيص سرطان البروستات إلا بعد أن يكون الورم السرطاني قد انتشر خارج الغدة.

عند معظم الرجال يتم الكشف للمرة الأولى عن وجود سرطان البروستات غالباً خلال فحص روتيني للكشف عن المستضد البروستاتي النوعي (PSA - Prostate - specific antigen) أو خلال الفحص الإصبعي للمستقيم كما هو مبين في

الشكل (3-3) ، عندما تظهر بالفعل أعراض أو علامات مبكرة تتعلق طبيعتها بدرجة تطور الورم السرطاني أو بمدى انتشاره في الأعضاء الأخرى.



الشكل (3-3) تشخيص سرطان البروستات.

قد تشمل الأعراض الأولى لوجود ورم سرطاني في غدة البروستات مشكلات في التبول ناجمة عن الضغط الذي يشكله الورم السرطاني على المثانة أو على الأنبوب الذي ينقل البول من المثانة.

إن مشكلات التبول يمكن أن تكون في العادة علامة على العديد من المشكلات الحميدة غير الخبيثة في غدة البروستات، مثل: تضخم البروستات الحميد، أو التهاب البروستات، حيث أن أقل من 5% من حالات السرطان في البروستات تكون مصحوبة بمشكلات التبول كعلامة أولى وأولية. (Litwin & Tan, 2017)

بعض أعراض سرطان البروستات:

1. علامات تصاحب مشكلات التبول

- العلامات التي يمكن أن تدل على مشكلات في التبول تشمل الآتي:
- صعوبة في التبول.
- بداية خروج البول ثم توقفه أكثر من مرة أثناء التبول.
- ضغط متزايد في تدفق البول.

2. علامات انتشاره في المناطق القريبة

أما سرطان البروستات أو في المناطق القريبة من غدة البروستات فيمكن أن يسبب الأعراض الآتية:

■ ظهور دم في البول.

■ ظهور دم في السائل المنوي.

3. علامات انتشاره إلى الغدد الليمفاوية

إذا كان سرطان البروستات قد انتقل إلى الغدد الليمفاوية وانتشر فيها فقد يؤدي إلى الآتي:

■ تورم في الساقين.

■ شعور بعدم الراحة في الحوض.

4. علامات انتشاره إلى العظام

إذا كان سرطان البروستات قد انتشر نحو العظام فيمكن أن يؤدي إلى الأعراض الآتية:

■ ألم مستمر في العظام.

■ ظهور كسور في العظام.

■ الضغط على العمود الفقري.

3-4. أسباب وعوامل خطر سرطان البروستات

السرطان هو مجموعة من الخلايا غير الطبيعية التي تتكاثر بوتيرة أسرع من الخلايا الطبيعية وترفض أن تموت، والخلايا السرطانية تتمتع بالقدرة على غزو الأنسجة السليمة والتسبب بتدميرها، إما عن طريق النمو بشكل مباشر على الجزء العلوي من الأنسجة المحيطة بها وإما بعد الانتقال إلى أعضاء أخرى في الجسم عبر الدورة الدموية أو عن طريق الغدد الليمفاوية. الورم السرطاني المجهرى الذي لا يمكن أن يُرى إلا بالمجهر يمكن أن يتطور على شكل عناقيد صغيرة تواصل النمو والتطور لتصبح نسيجاً أكثر كثافة وأشدّ صلابة.

ليس معروفاً حتى الآن السبب الحقيقي الدقيق الذي يؤدي إلى تكوّن وتطور سرطان البروستات، ولماذا تتصرف أنواع معينة من الأورام السرطانية بشكل مختلف عن غيرها، يرى الباحثون أن مزيجاً من عدة عوامل مختلفة هي المسؤولة عن هذا التطور وتشكل مفتاحاً لفهمه وتشمل هذه العوامل:

1. الوعي: يشكل الوعي بعوامل الخطر للإصابة بسرطان البروستات عنصراً هاماً يمكن أن يُساعد المرء على اتخاذ

قراراته بشأن ما إذا كان بحاجة لإجراء فحص للكشف المبكر عن سرطان البروستات.

2. العمر: عند تجاوز عمر 50 عاماً يرتفع مستوى خطر الإصابة بسرطان البروستات.

3. التاريخ الطبي العائلي: إذا كان أحد الأشقاء أو الأب مصاباً بسرطان البروستات فإن خطر الإصابة به يزداد، ويكون أعلى بكثير من رجال آخرين.

4. التغذية: الرجال الذين يتناولون غذاءً غنياً بالدهون والرجال ذوو الوزن الزائد هم أكثر عُرضة للإصابة بسرطان البروستات، وتقول إحدى النظريات أن الدهون تشجع على إنتاج هرمون التستوستيرون (Testosterone) الذي يمكن أن يشجع إنتاج الخلايا السرطانية.

5. مستويات مرتفعة من هرمون التستوستيرون:

بما أن هرمون تستوستيرون يحفز ويسرع نمو غدة البروستات، فإن الرجال الذين يتناولون علاجاً يشكل هذا الهرمون أساسه أو مركباً أساسياً فيه يكونون أكثر عرضة للإصابة بسرطان البروستات من الرجال الذين لديهم مستويات أقل من هرمون التستوستيرون.

كما يشير الأطباء بقلق إلى أن العلاج بهرمون التستوستيرون قد يحفز انتشار سرطان البروستات وتقسّيه إذا كان موجوداً بالفعل، كما أن العلاج بهرمون التستوستيرون لفترة طويلة ومتواصلة قد يؤدي أيضاً إلى تضخم غدة البروستات (المرجع 6).

3-5. مضاعفات سرطان البروستات

المضاعفات الناجمة عن سرطان البروستات قد تكون نتيجة مباشرة للمرض نفسه أو نتيجة للعلاج،

تتوفر اليوم علاجات مختلفة يمكن بواسطتها مواجهة هذه المشكلات ومعالجتها، أما المضاعفات الأكثر شيوعاً التي تصاحب سرطان البروستات فتشمل ما يأتي:

- الاكتئاب.
- انتشار السرطان وتقسّيه.
- الأوجاع.
- صعوبات في التبول.
- ضعف الأداء الجنسي أو العجز الجنسي التام.

3-6. تشخيص سرطان البروستات

3-6-1 بروتوكول التشخيص

- بعد ان تم أخذ القصة العائلية للمريض التي تتضمن (الاسم , المهنة , مكان السكن , العادات الحياتية (تدخين, كحول) , الأمراض الوراثية)
- نبدأ بسوابق المريض التي قد تكون كالتالي : سوابق جراحية (عمليات جراحية على منطقة الحوض والعجان , فتق اربي , كيسات مائية , بواسير وشقوق شرجية) او اي عملية أخرى
- نستعلم عن السوابق الدوائية (وهي الأدوية التي يأخذها المريض عادة مثل أدوية الضغط والسكري أو معالجة هرمونية تعويضية للتستسترون أو هرمون النمو GH)
- نبدأ بالقصة السريرية أي السبب الذي دفع المريض لزيارة الطبيب والتي قد تتضمن (نقطيش البول , ألم بعد الانتهاء من التبول , ألم في منطقة العجان , تعدد بيلات , ضعف جنسي)
- خطوات الفحص السريري :
 - بالتأمل قد نجد ندبة جراحية في منطقة العجان أو البطن ووجودها يدفعنا للشك أن تضخم البروستات أحد مضاعفاتها
 - المس الشرجي : يتم بواسطة أذخال السبابة في فتحة الشرج وجس البروستات من الجدار الأمامي للقناة الشرجية , ان وجود ضخامة بروستاتية محسوسة قد يشير الى وجود سرطان البروستات ولكنه لا يكون مؤكداً لأنه من الممكن أن يكون ضخامة حميدة خاصة لدى الرجال الكهول (خمسون عام وما فوق)
 - السؤال عن اعراض السرطان العامة (نقصان وزن , ترفع حراري , هزال , وهن عام) فاذا ترافقت أعراض السرطان العامة مع تضخم البروستات يشير الى احتمالية أكبر بأن هذا التضخم خبيث .
- التشخيص المخبرية :
 - ❖ يقوم المريض بتحليل مخبري لما يلي (تعداد وصيغة CPC , فحص الكريات البيض , CRP , PSA (وهو الأهم))
 - ❖ ارتفاع الكريات البيض وال CRP قد يحدث بسبب التهاب المحدث من قبل السرطان
 - ❖ أن ارتفاع الواسم الورمي PSA هو أهم تشخيص مخبري في تشخيص ضخامة البروستات حيث أن :
 - ❖ الواسم الورمي أو المستضد النوعي PSA هو عبارة عن بروتين سكري يصنع من قبل البروستات بالحالة الطبيعية ولكن زيادة ارتفاعه عن الحد الطبيعي يوجه الى ضخامة في غدة البروستات
 - إذا أظهر اختبار الدم لسرطان البروستات أن مستوى ال PSA لا يتجاوز (4 نانوغرام/مل) , فعلى الأرجح أن المريض لا يعاني من مرض ورمي , أن معدل اكتشاف الورم أثناء الخزعة في هذه الحالة (0.5%)

إذا كان ال PSA أعلى من (20 نانوغرام/مل) فإن احتمالية اكتشاف السرطان تصل الى (75%) لذلك , عند هذا المستوى من واسمات السرطان , يتم تعيين خزعة على الفور لتأكيد أو استبعاد وجود السرطان من فحص الأنسجة تشكل اكبر صعوبة تشخيصية ما تسمى " المنطقة الرمادية" , وهي لمجموعة من المرضى الذين لديهم مستوى ال PSA (أعلى من 4 نانوغرام/مل وأقل من 15 نانوغرام) , وبما أنه من الصعب جدا الكشف عن سرطان البروستات في المراحل المبكرة وأيضا عدم اجراء الخزعة من قبل الجميع (هذا الاجراء مؤلم وأحيانا مصحوب بمضاعفات) , فيستخدم طرق اخرى لزيادة دقة التحليل ومنها :

1- التصوير بالامواج فوق الصوتية مع اجراء خزعة :

في التصوير بالأمواج فوق الصوتية يتم الأخذ بعين الاعتبار فيما اذا كان الجدار غير متجانس (بسبب عدم تمايز الخلايا السرطانية الى درجة تمايز الخلايا الطبيعية البروستاتية) و وفي وجود ضخامة في البروستات , ايضا قد نرى في التصوير بالأمواج فوق الصوتية حالات توسع في الاحليل المثانة قبل أن ينتقل الى مرحلة الاحليل البروستاتي

ومن خلال الخزعة نحسب درجة السرطان بمقياس غليسون

2- التصوير بالرنين المغناطيسي :

يتم اجراء عملية التصوير بالرنين المغناطيسي متعدد المعاملات فاذا وجد منطقة مغايرة في التباين (سويات رمادية مختلفة عن السويات الرمادية لغدة البروستات) فيشك بوجود سرطان ويتم حساب درجة السرطان من

مقياس PI-RADS v2

3-6-2 أنواع الفحوصات

قد يكون سرطان البروستات غير مصحوب بأي أعراض في البداية، من الممكن جداً أن يكون العرض الأول الذي يظهر يتمثل في مشكلة معينة يتم اكتشافها فقط بواسطة إجراء أحد فحوصات المسح المختلفة، مثل:

A. الفحص الإصبعي للمستقيم (FRE - Finger Rectal Examination).

B. فحص عن المستضد البروستاتي النوعي (PSA - Prostate - specific antigen).

C. تصوير بالأمواج فوق الصوتية (Ultrasound) من خلال فتحة الشرج.

D. خزعة (Biopsy) من غدة البروستات.

E. تصوير البروستات بالرنين المغناطيسي متعدد المعاملات (mpMRI)

3-7. تصنيف سرطان البروستات

حين تؤكد نتائج فحص الخزعة وجود ورم سرطاني تأتي الخطوة التالية وهي التصنيف والتي هدفها تحديد مدى فتك السرطان وتفشيه، يتم فحص عينات من النسيج ويتم إجراء مقارنة بين الخلايا السرطانية وبين خلايا البروستات السليمة. كلما زادت درجة الاختلاف بين الخلايا السرطانية والخلايا السليمة يكون مستوى فتك السرطان أعلى ويزيد احتمال انتشاره بسرعة أكبر.

تختلف الخلايا السرطانية فيما بينها عادةً من حيث الشكل والحجم، فبعض هذه الخلايا قد يكون فتاكاً جداً بينما لا يكون بعضها الآخر فتاكاً على الإطلاق، ويستطيع اختصاصي علم الأمراض تحديد النوعين الأكثر فتكاً من الخلايا السرطانية وتشخيص درجة شدتهما وخطورتهما.

التدرجات الأكثر شيوعاً لتحديد مستوى الإصابة بسرطان البروستات أما عن طريق أخذ خزعة ويتقرر بحسب مقياس غليسون أو بمقياس PI-RADS v2 لصور المران

3-7-1 تحديد السرطان بمقياس غليسون

يحدد حاصل جمع العددين اللذين تم الحصول عليهما التدرج العام للورم السرطاني لدى الشخص المعين الذي يخضع للفحص، وهذا التدرج يمكن أن يتراوح بين 2 - 10 وهو سرطان فتاك جداً.

بعد تحديد مدى شدة سرطان البروستات ودرجة فتكه تأتي الخطوة التالية التي تدعى التدرج التي تحدد إلى أي مدى قد انتشر السرطان وتفشى، ويتم تدرج سرطان البروستات عادةً وفق أربعة مستويات بحسب مدى انتشاره:

الدرجة الأولى (t1): هذه الدرجة تشير إلى مرحلة أولية للغاية من السرطان، إذ لا يزال محصوراً في منطقة مجهرية لا يستطيع الطبيب استشعارها باللمس.

الدرجة الثانية: في هذه الدرجة يمكن استشعار الورم السرطاني، لكنه لا يزال محصوراً في نطاق غدة البروستات فقط.


الدرجة الثالثة: في هذه الدرجة يكون الورم السرطاني قد انتقل وانتشر إلى خارج غدة البروستات وإلى الحويصلتين المنويتين أو إلى الأنسجة المجاورة.

الدرجة الرابعة: في هذه الدرجة يكون الورم السرطاني قد انتشر وتفشى في الغدد اللمفاوية، أو العظام، أو الرئتين أو أعضاء أخرى في الجسم (Litwin & Tan, 2017).

2-7-3 تحديد السرطان بمقياس PI-RADS v2

لتلبية متطلبات تشخيص سرطان البروستات، قامت الكلية الأمريكية للأشعة (American College of Radiology)، والجمعية الأوروبية لأشعة الجهاز البولي التناسلي (European Society of Urogenital Radiology (ESUR))، ومؤسسة AdMeTech بعقد لجنة خبراء دولية لتطوير الإصدار 2 من نظام تقارير وبيانات تصوير البروستات (Prostate Imaging Reporting and Data System version 2 (PI-RADS v2)) (Weinreb et al., 2016).

تم تصميم PIRADS v2 لتوحيد تقنيات الحصول على الصور وتفسير التصوير بالرنين المغناطيسي للبروستات، وهو أمر بالغ الأهمية للإدارة والاتصالات والأبحاث المقارنة التي تشمل مؤسسات متعددة، وضمان الجودة للتجارب متعددة المراكز. وقد حظي PI-RADS v2 بقبول دولي سريع وواسع النطاق بين أطباء الأشعة وأطباء المسالك البولية، ويستخدم على نطاق واسع في الممارسة والأبحاث اليومية (المرجع 12)، يبين الشكل (3-4) تقسيمات البروستات من أجل تحديد درجة السرطان.




الشكل (3-4) PIRADS v2. ملاحظات: (a) تسعة وثلاثون منطقة من البروستات

في الواقع، لقد وثقت الدراسات الحديثة تأثير PI-RADS v2 على اكتشاف csPCa (Turbey et al., 2019). لضمان إمكانية تدريب أخصائيي الأشعة بشكل صحيح على PI-RADS v2، يتم تقديم الدورات التعليمية من قبل العديد من المنظمات.

تم تطوير PI-RADS v2 من خلال عملية قائمة على الإجماع باستخدام مجموعة من البيانات المنشورة وملاحظات وآراء الخبراء. وبعد 3 سنوات من التطوير، تم إصداره عبر الإنترنت (<https://www.acr.org/Quality-Safety/PI-RADS>) في أواخر عام 2014 وتم نشره في أوائل عام 2016.

وفي وقت لاحق، أثبتت العديد من الدراسات صحة قيمة PI-RADS v2، ولكن، كما هو متوقع، أظهرت أيضاً بعض التناقضات والقيود. على سبيل المثال، كان الاتفاق بين المراقبين جيداً إلى متوسطاً فقط، وتم تحديد عدد من معايير التقييم المحددة، والتي تتطلب التوضيح أو التعديل. علاوة على ذلك، فإن بعض القضايا التقنية المتعلقة بالحصول على بيانات mpMRI قد تستفيد من التحديث والتحسين (Rosenkrantz et al., 2016).

ولمعالجة هذه المشكلات، أوصت اللجنة التوجيهية لـ PI-RADS، مرة أخرى باستخدام عملية قائمة على الإجماع، بعدة تعديلات على PI-RADS v2، مع الحفاظ على إطار تعيين الدرجات للتسلسلات الفردية واستخدام هذه الدرجات لاستخلاص فئة تقييم شاملة. ونظراً للنطاق المحدود لهذه التحديثات، يُطلق على الإصدار المحدث اسم PI-RADS v2.1. نظام PI-RADS v2 هو المبدأ التوجيهي القياسي لقراءة والحصول على التصوير بالرنين المغناطيسي للبروستات، ولكنه يتبع تقييماً نوعياً وشبه كمي يتطلب خبرة كبيرة لإجراء التصوير بالرنين المغناطيسي المناسب الاستخدام. وفي الوقت نفسه، يمكن أن يظهر csPCa كآفات متعددة البؤر ذات أشكال وأحجام مختلفة، وتحمل تشابهاً قوياً مع العديد من الحالات غير الخبيثة، كما هو موضح في الشكل (3-5). (Weinreb et al., 2016)




الشكل (3-5) التحدي المتمثل في تمييز csPCa بسبب عدم تجانسه المورفولوجي

فئات التقييم

يتم التنبؤ باحتمالية الإصابة بالسرطان ذو الأهمية السريرية، والذي يتم تعريفه على أنه وجود أي من الحالات الستة التالية في الشكل (3-6)

تكون احتمالية الإصابة بالسرطان عالية عندما:

- 3 حالات فيها درجة جليسون $\text{Gleason score} \leq 7$ (بما في ذلك 4+3 مع مكون جليسون 4 البارز ولكن ليس السائد)
- الحجم < 0.5 مل
- تمديد خارج البروستات extraprostatic extension



الشكل (3-6) فئات التقييم PI-RADS™ v2 (Steiger et al., 2016)

يتم تعيين درجة من 1 إلى 5 لكل آفة تشير إلى احتمال الإصابة بسرطان مهم سريرياً كما هو مبين في الشكل (3-7) والدرجات تكون كالتالي:

- PI-RADS 1: منخفض جداً (من غير المرجح أن يوجد سرطان ذو أهمية سريرية)
- PI-RADS 2: منخفض (من غير المرجح أن يوجد سرطان ذو أهمية سريرية)
- PI-RADS 3: متوسط (وجود سرطان مهم سريرياً أمر ملتبس)

-
- The flowchart illustrates the PI-RADS v2.1 algorithm for prostate cancer MRI. It starts with an 'Abnormality location' box at the top, which branches into 'Peripheral Zone' and 'Transition Zone'. The 'Peripheral Zone' path leads to 'DWI/ADC' and then to 'Score 1' through 'Score 5'. The 'Transition Zone' path leads to 'T2-WI' and then to 'Score 1' through 'Score 5'. The scores are then mapped to PI-RADS categories: Score 1 is 'PI-RADS 1 - Very low', Score 2 is 'PI-RADS 2 - Low', Score 3 is 'PI-RADS 3 - Intermediate', Score 4 is 'PI-RADS 4 - High', and Score 5 is 'PI-RADS 5 - Very High'. For the 'Peripheral Zone', the scores are directly mapped. For the 'Transition Zone', the scores are mapped to PI-RADS 1-4, but there is a specific rule for Score 3: if 'DWI ≤ 4', it maps to PI-RADS 3; if 'DWI 5', it maps to PI-RADS 4. Additionally, for the 'Peripheral Zone', there is a decision point for 'DCE -' (maps to PI-RADS 3) and 'DCE +' (maps to PI-RADS 4).
- ```

graph TD
 AL[Abnormality location] --> PZ[Peripheral Zone]
 AL --> TZ[Transition Zone]

 PZ --> DWIADC[DWI/ADC]
 DWIADC --> S1PZ[Score 1]
 S1PZ --> S2PZ[Score 2]
 S2PZ --> S3PZ[Score 3]
 S3PZ --> S4PZ[Score 4]
 S4PZ --> S5PZ[Score 5]

 TZ --> T2WI[T2-WI]
 T2WI --> S1TZ[Score 1]
 S1TZ --> S2TZ[Score 2]
 S2TZ --> S3TZ[Score 3]
 S3TZ --> S4TZ[Score 4]
 S4TZ --> S5TZ[Score 5]

 S1PZ --> PI1[PI-RADS 1 - Very low
(Clinically significant cancer is highly unlikely)]
 S2PZ --> PI2[PI-RADS 2 - Low
(Clinically significant cancer is unlikely)]
 S3PZ --> PI3[PI-RADS 3 - Intermediate
(Clinically significant cancer is equivocal)]
 S4PZ --> PI4[PI-RADS 4 - High
(Clinically significant cancer is likely)]
 S5PZ --> PI5[PI-RADS 5 - Very High
(Clinically significant cancer is highly likely)]

 S1TZ --> PI1
 S2TZ --> PI2
 S3TZ --> PI3
 S4TZ --> PI4
 S5TZ --> PI5

 S3PZ -- DCE - --> PI3
 S3PZ -- DCE + --> PI4

 S3TZ -- DWI ≤ 4 --> PI3
 S3TZ -- DWI 5 --> PI4

```

27

ويقصر أوقات الفحص (Turkbey et al., 2019). وبالتالي، على الرغم من توفير معلومات تشخيصية أقل من mpRI، فإن bpMRI أكثر ملاءمة ضمن نطاق الفحص الكبير الحجم والمعتمد على السكان (Eklund et al., 2021).

### 3-8. علاج سرطان البروستات

ثمة أكثر من طريقة واحدة في علاج سرطان البروستات، بالنسبة لبعض الرجال يشكل الدمج بين عدد من العلاجات، مثل: الجراحة مع المعالجة الإشعاعية، أو المعالجة الإشعاعية مع المعالجة الهرمونية أفضل الحلول لحالاتهم.

اختيار طريقة العلاج الأفضل لكل حالة معينة تتعلق بعدة عوامل والتي تشمل سرعة نمو الورم السرطاني، وإلى أي مدى قد انتشر الورم، وعمر الرجل، وكم يتوقع أن يعيش، والإيجابيات والسلبيات المحتملة التي تصاحب كل علاج (Litwin & Tan, 2017).

تشمل العلاجات الأكثر شيوعاً واستخداماً لسرطان البروستات ما يأتي:

#### 3-8-1. العلاجات الإشعاعية الخارجية

في العلاج الإشعاعي الخارجي يتم استخدام الأشعة السينية القوية جداً لتدمير الخلايا السرطانية، هذا النوع من الإشعاع فعال جداً في تدمير الخلايا السرطانية لكنه قد يهاجم أنسجة سليمة أيضاً.

المضاعفات والأعراض الجانبية المترتبة عن العلاج الإشعاعي الخارجي تشمل الآتي:

- صعوبات في التبول.
- بُراز رخو وتغوّط مُدَمَّى أي نزف من الشرج.
- الشعور بالضيق وعدم الراحة أثناء عمل الأمعاء أو الشعور بالحاجة إلى عمل الأمعاء بشكل متواصل ومستمر.
- أعراض جانبية عند ممارسة النشاط الجنسي.

#### 3-8-2. العلاجات الإشعاعية الداخلية

أصبحت طريقة غرس الغرسة (Implant) المشعة داخل غدة البروستات خلال السنوات الأخيرة طريقة علاجية مقبولة وشائعة لمعالجة سرطان البروستات.

هذه الغرسة والتي تدعى مَعَالِجَةً كَثِيبَةً (Brachytherapy) أي المعالجة الإشعاعية التي تستخدم الأشعة المؤيّنة، حيث يوضع المصدر الإشعاعي على مسافة قصيرة وقريبة من الجسم أو العضو المُعالَج، وتعطي جرعة إشعاع أعلى بكثير من العلاج الإشعاعي الخارجي وعلى مدى فترة زمنية أطول.

هذه الطريقة العلاجية يتم استخدامها عادةً في معالجة الرجال الذين يكون الورم السرطاني لديهم صغيراً حتى متوسط الحجم، والذين يكون تدرجهم منخفضاً من حيث درجة المرض لديهم.

المضاعفات والأعراض الجانبية لغرس الغرسة المشعة تشمل الآتي:

صعوبات في التبول.

أعراض جانبية عند ممارسة النشاط الجنسي.

أعراض شرجية.

### 3-8-3. المُعالجات الهرمونية

العلاج الهرموني يهدف إلى منع الجسم من إنتاج هُرمون الذكورة التستوستيرون، الذي يمكن أن يحفّر إنتاج الخلايا السرطانية.

الآثار الجانبية للعلاج الهرموني تشمل الآتي:

- تضخم الثديين.
- كبت الرغبة الجنسية.
- العجز الجنسي.
- موجات من الحمّى.
- زيادة الوزن.
- انخفاض الكتلة العضلية وكتلة العظام.

الأدوية التي تشكل الهرمونات مركباتها الأساسية يمكن أن تسبب ما يأتي: غثيان، إسهال، تعب، بعض الأضرار للكبد.

### 3-8-4. استئصال غدة البروستات

إزالة غدة البروستات بواسطة العملية الجراحية والتي تدعى استئصال غدة البروستات يتم إجراؤها غالباً كوسيلة لمعالجة الورم السرطاني الذي لا يزال محصور في داخل غدة البروستات. (Litwin & Tan, 2017)

أثناء العملية يقوم الجراح باستخدام عدد من التقنيات الخاصة لاستئصال غدة البروستات والعقد للمفاوية المجاورة لها، هذه العملية الجراحية يمكن أن تؤثر على العضلات ومجموعات الأعصاب التي تتحكم بعملية التبول وعلى القدرات الجنسية.

تشمل المضاعفات الجانبية لاستئصال البروستات العجز الجنسي.



### 3-8-6. علاجات أخرى

تشمل العلاجات ما يأتي:

- المعالجة الكيميائية.
- المعالجة بالتجميد.
- المعالجة الجينية.

### 3-9 جهاز الرنين المغناطيسي (MRI)

#### 3-9-1 مبدأ عمل جهاز الرنين المغناطيسي

يعتبر جهاز الرنين المغناطيسي (MRI) من الأجهزة التصوير المسحية , حيث أن عملية المسح تعتمد على مجال مغناطيسي قوي مع أشعة راديوية لعمل صورة تفصيلية لأجزاء من جسم الانسان كالمفاصل الداخلية , الغضاريف , الأربطة , العضلات و الأوتار , والتي لا يمكن تصويرها بأجهزة الأشعة السينية (أشعة اكس X) او أجهزة الأمواج فوق الصوتية .

يصدر جهاز الرنين المغناطيسي مجالا مغناطيسيا قويا جدا , وبالتالي يجذب بروتونات عنصر الهيدروجين الموجود في التركيب الكيميائي لمياه جسم الانسان , والتي تدور في حركة مغزلية (محورية) وباتجاه معين , بالإضافة إلى انه يصدر تيارا من الترددات الراديوية التي تسبب تنوعا في قيمة المجال المغناطيسي , عندها تمتص البروتونات تلك الطاقة مما يقلب اتجاه حركة دورانها إلى أن ينقطع المجال المغناطيسي , وبعدها يعود اتجاه دوران البروتونات لوضعه الطبيعي

خلال تلك العملية من تغيير اتجاه دوران البروتونات ورجوعه للوضع الأصلي تنشأ موجة راديوية يتم رصدها من خلال مستقبل موجود في جهاز الرنين المغناطيسي ليتم استحصالها كصورة (Broadhouse , 2017)

#### 3-9-2 مكونات جهاز الرنين المغناطيسي

يتكون جهاز الرنين المغناطيسي من أربع مكونات رئيسية : مغناطيس رئيسي يتكون من ملفات فائقة التوصيل , ملفات تردد لاسلكي (RF) , ملفات متدرجة , ملفات تردد لاسلكي , أنظمة الحاسب

المغناطيس الرئيسي: يستخدم نظام مغناطيسي التصوير بالرنين المغناطيسي المبكر هيكل الصفائح المغناطيسية، حيث إن استخدام كميات كبيرة من الصفائح المغناطيسية يجعل وزن وحجم النظام كبيرا نسبيا ومع التطور السريع لتقنيات المغناطيس تم تطوير هيكل الصفائح النشطة بنجاح لنظام المغناطيس عالي المجال مما يقلل بشكل كبير من نطاق خط 5 غاوس

لفائف التدرج: تعد مجموعة لفائف التدرج مكونا مهما في جهاز الرنين المغناطيسي الذي ينتج مجالات مغناطيسية متدرجة خطية يتم فرضها فوق مجال مغناطيسي قوي موحد , ويتم انتاج المجال المغناطيسي المنتظم بواسطة مغناطيس رئيسي , والذي يتماشى مع اتجاه حركة البروتون , يغير المجال المغناطيسي المتدرج المتراكب بشكل طفيف تردد أو طور حركة البروتون , بالتالي تشفير المعلومات المكانية للجسم المصور في التردد المرتبط بموقع في الفضاء, وبشكل عام يجب ان يكون تدرج المجال المغناطيسي الناتج عن ملفات التدرج خطيا قدر الامكان.

لفائف التددات اللاسلكية : ملف (RF) هو المكون الرئيسي لنظام التصوير بالرنين المغناطيسي حيث يعمل كمرسل وكذلك كمستقبل في تشكيل الصور النهائية , وهناك أنواع مختلفة من هذه الملفات ويكمن الاختلاف بينها في استخدامها لأجزاء مختلفة من جسم الانسان وقوى المجال مختلفة أيضا (Broadhouse , 2017)


### 3-9-3 الأسس الفيزيائية للتصوير بالرنين المغناطيسي

ماسح التصوير بالرنين المغناطيسي هو عبارة عن مغناطيس عملاق , ويجري قياس قوة المغناطيس بوحدة تسمى تسلا (T) , وتبلغ قوة المجال المغناطيسي لمعظم ماسحات التصوير بالرنين المغناطيسي المستخدمة في المستشفيات وعيادات البحث الطبي 1.5 أو 3 تسلا .

تتموضع بروتونات الهيدروجين جميعها في مواقع عشوائية في الجسم وتدور على محورها , ومع ذلك تتغير هذه العشوائية عندما نضع جسم الإنسان داخل مجال مغناطيسي قوي جدا , مثل ماسح التصوير بالرنين المغناطيسي

عندما توضع بروتونات الهيدروجين التي تدور بشكل عشوائي داخل ماسح التصوير بالرنين المغناطيسي فإن محاورها تعدل محاذاتها مع المجال المغناطيسي الأقوى للماسح كما هو موضح في الشكل (3-8), ويسمى المجال المغناطيسي للماسحات بمجال B0 , فتصطف بعض برتينات الهيدروجين الأعلى (موازيا للمجال المغناطيسي) وبعضها الآخر يصطف للأسفل (مضادا للتوازي) بينما لا تزال تدور حول محورها , بالنظر لمبدأ فيزياء الكم سيكون عدد البروتونات المتجهة للأعلى أكبر بقليل من البروتونات المتجهة للأسفل .





الشكل (3-8) بروتونات الهيدروجين وكيفية حركتها في المجال المغناطيسي

وهذه المغناطيس الصغيرة تلغي بعضها تقريبا ليبقى فقط المجال المغناطيسي المتولد من نسبة صغيرة من البروتونات المتجهة للأعلى وهذا هو المجال الصغير الذي يمكن قياسه باستخدام التصوير بالرنين المغناطيسي .

لا يؤثر المجال B0 على اصناف البروتونات فحسب بل ايضا على مدى سرعة دوران هذه البروتونات (تردد الحركة المدارية) , ويعتمد تردد الحركة المدارية على قوة المجال المغناطيسي , وكلما زادت قوة المجال المغناطيسي زادت سرعة دورانها وهذا مهم جدا لاستخدام التصوير بالرنين المغناطيسي لقياس الاشارة الصادرة من جزيئات الهيدروجين .

الفرق بين (T1) و (T2) :

ان T1 تحتاج لـ TR (زمن تكرار) ضمن المجال (ميلي ثانية 400-700) و TE (الزمن الى الصدى)

بين (ميلي ثانية 10-30)

بينما T2 يكون الـ TR (ميلي ثانية 2000+) والـ TE (ميلي ثانية 70+)

تستخدم الـ T2 عند الحاجة إلى إشارة عالية الكثافة من الماء مثل التصوير في العمود الفقري و المفاصل، بينما الـ T1 عندما يكون من الضروري مشاهدة التشريح في مستويات متعددة . (Broadhouse , 2017)

### 3-9-4 جهاز الرنين المغناطيسي ثنائي المعاملات (bpMRI)

يبرز التصوير بالرنين المغناطيسي ثنائي القياس (bpMRI) للبروستاتا الذي يجمع بين التصوير المورفولوجي المرجح T2 والتصوير المرجح بالانتشار (DWI) ومعامل الانتشار الظاهر (ADC) الناتج عن DWI كبديل للتصوير بالرنين المغناطيسي متعدد القياسات (mpMRI) للكشف عن خزعة البروستاتا المستهدفة وتحديد موقعها وتوجيهها لدى المرضى الذين يشتبه في إصابتهم بسرطان البروستاتا (PCa)

حيث يتغلب التصوير بالرنين المغناطيسي ثنائي المعاملات على بعض قيود التصوير بالرنين المغناطيسي متعدد المقاييس (mpMRI) مثل التكاليف والوقت اللازم لإجراء الدراسة واستخدام عوامل التباين القائمة على الغادولينيوم وعدم وجود توجيه لإدارة الآفات من الدرجة 3 التي لا يمكن تحديدها بالنسبة لسرطان البروستاتا الشخصي الكبير.

من خلال التجارب وجد أن النتائج السريعة المثلثة والمتشابهة للتصوير بالرنين المغناطيسي ثنائي المعاملات (bpMRI) مقارنةً بالتصوير بالرنين المغناطيسي (mpMRI) ترتبط بشكل أساسي بالتصوير المرجح بالانتشار DWI الذي نعتبره التسلسل السائد للكشف عن الأورام PCa المشبوهة في كل من المنطقة الانتقالية والمنطقة المحيطة

### 3-10 البرامج المستخدمة:

#### 3-10-1 برنامج ماتلاب Mtlab :

يعتبر الماتلاب من أهم البرامج الرائدة في التطبيقات الهندسية والرياضية ومن أكثر البرامج المستخدمة من قبل المهندسين والعلماء في أنحاء العالم من إنتاج شركة mathworks , وهي لغة عالية الأداء للحوسبة التقنية. فهو يدمج الحساب والتصور والبرمجة في بيئة سهلة الاستخدام حيث يتم التعبير عن المشكلات والحلول في تدوين رياضي مألوف. تشمل الاستخدامات النمذجية ما يلي:


الرياضيات والحساب , تطوير الخوارزميات, النمذجة والمحاكاة والنماذج الأولية , تحليل البيانات والاستكشاف , الرسومات العلمية والهندسية , تطوير التطبيقات , بما في ذلك بناء واجهة المستخدم الرسومية.

ماتلاب هو نظام تفاعلي كما هو مبين في الشكل (3-9) يكون عنصر بياناته الأساسي عبارة عن مصفوفة لا تتطلب أبعاد. يتيح لك ذلك حل العديد من مشكلات الحوسبة التقنية , خاصة تلك التي تحتوي على تركيبات المصفوفة والمتجهات , في جزء صغير من الوقت الذي ستستغرقه كتابة برنامج بلغة عددية غير تفاعلية مثل C أو فورتران (Fortran) , تطورت ماتلاب على مدى سنوات مع مداخلات من العديد من المستخدمين.

في البيئات الجامعية ، هي الأداة التعليمية الاساسيه للدورات التمهيديّة والمتقدمة في الرياضيات والهندسة والعلوم ، وفي الصناعة ، ماتلاب هي الأداة المفضلة للبحث والتطوير والتحليل عالي الإنتاجية.

تنقسم لقسمين: إضافات خاصه بماتلاب وإضافات خاصة بسميوليك الإضافات الخاصة بالماتلاب تُسمى صناديق العدة (Toolbox) هذه الصناديق تختلف عن بعضها البعض .

إذا لكل صندوق تخصص علمي تعالجه فهي تحوي بداخلها تعليمات برمجية تؤدي إلى حل المسائل العلمية في التخصص الذي أنشئت من أجله الأداة مثل أداة معالجة الصور فهي تعالج تخصص تحليل الصور وكتابة خوارزميات لترتيب البكسلات. (website 5)




الشكل (3-10) واجهة ماتلاب

### 2-10-3 برنامج 3D-slicer :

3D-slicer هو برنامج مجاني مفتوح المصدر وهو عبارة عن منصة معيارية مرنة لتحليل الصور وتصورها كما هو مبين في الشكل (3-10).

تم توسيع 3D-slicer للتمكين من تطوير كل من أدوات المعالجة التفاعلية وأدوات المعالجة المجمعة لمجموعة متنوعة من التطبيقات (website 4)



الشكل (3-11) واجهة 3D-slicer

من مزايا 3D-slicer :


- ❖ اظهار المستويات بصورة ثلاثية الأبعاد
- ❖ التعامل مع صور DICOM وقراءة / كتابة مجموعة متنوعة من الصيغ الأخرى
- ❖ دمج البيانات وتسجيلها بشكل مشترك باستخدام خوارزميات برمجية
- ❖ تجزئة الصورة التلقائية واليدوية
- ❖ تحليل وتصوير بيانات التصوير بالانتشار
- ❖ تحويل صيغ الصور الى Dicom

### 3-10-3 برنامج Evorad workstation :

هو محطة عمل ومعالجة سهل الاستخدام , تم تطويره من خلال التعاون لعدة سنوات مع أطباء الأشعة يسمح بإمكانات عالية لمعالجة الصور الموسعة بما في ذلك إعادة البناء ثلاثي الأبعاد ، وعرض الحجم مما يسمح بأكثر من عملية إعادة بناء في نفس الوقت

يحتوي واجهة مبنية لعدد غير محدود من المرضى/الاختبارات المفتوحة في نفس الوقت , مع العديد من الميزات الأخرى مثل إمكانية تحويل الصوت إلى نص لسهولة وسرعة إعداد التقارير كما هو مبين في الشكل (3-11). (3 website)





الشكل (3-12) واجهة Evorad

### 11-3 الذكاء الاصطناعي

#### 11-3-1 تعريف الذكاء الاصطناعي وتطبيقاته

الذكاء الاصطناعي وهو مجال علمي يهدف إلى أتمتة الأنشطة التي تتطلب ذكاءً بشرياً عن طريق بناء مجموعة من الخوارزميات البرمجية، وقد استُخدم هذا المجال منذ العقدين الماضيين كأداة للتطوير في مجالات مختلفة مثل التنبؤ والرعاية الصحية والأمن، ويقوم بالتخطيط بين النموذج المدخلات والمخرجات المتوازنة للبيانات المتاحة باستخدام التعلم الآلي من خلال تقديم مدخلات النموذج ومخرجاته بشكل متكرر. (المرجع 20)

يقوم الذكاء الاصطناعي باختيار النموذج المناسب الذي يحقق النتائج المرجوة من خلال ملاءمته مع الميزانية المتاحة وبيانات التدريب المتاحة. ويراقب الذكاء الاصطناعي النظام و أدائه ويساعد المؤسسة على بناء ثقة العملاء.

بدءاً من علاج وتشخيص السرطان، مروراً بضمان سلامة الأغذية من أجل تزايد عدد السكان، إلى تحليل التغير المناخي حيث يوفر الذكاء الاصطناعي حلاً رئيسية لحل التحديات التي يواجهها المجتمع. (Kumar.et al , 2023)

### 2-11-3 دور الذكاء الاصطناعي في الرعاية الصحية

يمكن للذكاء الاصطناعي أن يساعد مقدمي الرعاية الصحية في مجموعة متنوعة من رعاية المرضى والأنظمة الصحية الذكية. وتنتشر تقنيات الذكاء الاصطناعي التي تتراوح بين التعلم الآلي والتعلم العميق في مجال الرعاية الصحية لتشخيص الأمراض واكتشاف الأدوية وتحديد مخاطر المرضى. مع الحاجة إلى العديد من مصادر البيانات الطبية لتشخيص الأمراض بشكل مثالي باستخدام تقنيات الذكاء الاصطناعي، مثل التصوير بالموجات فوق الصوتية والتصوير بالرنين المغناطيسي والتصوير الشعاعي للثدي والتصوير الجيني والتصوير المقطعي المحوسب

وعلاوة على ذلك، عزز الذكاء الاصطناعي في المقام الأول تجربة المستوصف وسرّع من عملية إعداد المرضى لمواصلة إعادة تأهيلهم في المنزل. (Kumar.et al , 2023)

تقدم الرعاية الصحية الرقمية العديد من الفرص لتقليل الأخطاء البشرية، وتحسين النتائج السريرية، وتتبع البيانات بمرور الوقت، وتتسم أساليب الذكاء الاصطناعي من التعلم الآلي إلى التعلم العميق بوظيفة حاسمة في العديد من المجالات المتعلقة بالرعاية الصحية ، بما في ذلك تحسين الأنظمة السريرية الجديدة ومعلومات المرضى وسجلاتهم، وعلاج الأمراض المختلفة ، كما أن تقنيات الذكاء الاصطناعي هي الأكثر كفاءة في تحديد تشخيص أنواع مختلفة من الأمراض

وقد استخدم الباحثون العديد من التقنيات القائمة على الذكاء الاصطناعي مثل نماذج التعلم الآلي والتعلم العميق للكشف عن أمراض مثل الجلد والكبد والقلب والألزهايمر والأمراض السرطانية وغيرها من الأمراض التي تحتاج إلى تشخيص مبكر. كمثال يتم تقديم تقنيات مثل آلة بولتزمان (Boltzmann)، وآلة ناقلات الدعم (SVM)، وشجرة القرار (decision tree)، والانحدار اللوجستي (logistic regression)، والمنطق الضبابي (fuzzy logic)، والشبكة العصبية الاصطناعية لتشخيص الأمراض. (Kumar.et al , 2023)

### 3-11-3 التعلم الآلي machine learning


هو فرع من فروع الذكاء الاصطناعي وإحدى علوم الحاسوب، وحقيقة أن هذا العلم يركز بشكل كبير على استخدام البيانات (بيانات التدريب) والخوارزميات، ببساطة ، التعلم الآلي هو طريقة لتمكين أجهزة الكمبيوتر من تنفيذ مهام محددة دون تفسير صريح لكل سطر من أجل تقليد الطريقة التي يتعلم بها الإنسان والعمل على تحسينها بشكل تدريجي، لذلك فإن التعلم الآلي عبارة عن برنامج يظهر قدرة معرفية تتشابه إلى حد كبير مع قدرة الإنسان، فهو يهدف إلى جعل أجهزة الكمبيوتر تفكر وتحل مختلف المشاكل التي تواجهها بالطريقة التي يقوم بها الإنسان الطبيعي، من خلال الاستفادة من النماذج الاحصائية وخوارزميات التعلم

ويتألف من سلسلة من العقد / الخلايا العصبية المرتبطة ببعضها البعض. هناك ثلاث طبقات مختلفة: طبقة الإدخال ، والطبقة المخفية ، وطبقة الإخراج. تأخذ طبقة الإدخال البيانات إلى الشبكة ، حيث يتم معالجتها بواسطة العقد الموجودة في الطبقة الوسطى / المخفية. العقد في الطبقة المخفية هي وظائف رياضية يمكنها معالجة البيانات القادمة من طبقة الإدخال ، واستخراج الأنماط ذات الصلة من بيانات الإدخال. هذه هي الطريقة التي "تتعلم" بها الشبكة العصبية. تحصل الشبكات العصبية على اسمها من حقيقة أنها مستوحاة من بنية ووظيفة الدماغ البشري. (website 1)

### 4-11-3 التعلم العميق Deep learning

التعلم العميق هو المصطلح الذي يطلق على بنى التعلم الآلي التي تربط العديد من الإدراك متعدد الطبقات معًا ، بحيث لا توجد طبقة مخفية واحدة فقط ولكن العديد من الطبقات المخفية. كلما كانت الشبكة العصبية العميقة "أعمق" ، يمكن أن تتعلم الأنماط الأكثر تعقيدًا.

يُشار أحيانًا إلى شبكات الطبقة العميقة المكونة من الخلايا العصبية على أنها شبكات متصلة بالكامل أو طبقات متصلة بالكامل ، مما يشير إلى حقيقة أن خلية عصبية معينة تحافظ على اتصال بجميع الخلايا العصبية المحيطة بها. يمكن دمج الشبكات المتصلة بالكامل مع وظائف التعلم الآلي الأخرى لإنشاء بنى تعلم عميق مختلفة. (website 1)



الشكل (3-13) صورة توضيحية للتعلم العميق



## الفروق بين التعلم العميق والتعلم الآلي:

أولاً : أن التعلم الآلي يعمل على كمية محدودة من البيانات أما التعلم العميق يعمل على كمية كبيرة

ثانياً: التعلم الآلي يقسم المهمة الى مهام فرعية ويحللها بشكل منفرد ويجمع النتائج في النهاية أما التعلم العميق لا يقسم المهمة

ثالثاً: التعلم الآلي يستغرق وقتاً اقل في التدريب من التعلم العميق

رابعاً: التعلم الآلي يستغرق وقتاً اطول في الاختبار من التعلم العميق

هناك مجموعة متنوعة من أبنية التعلم العميق التي يستخدمها الباحثون والمهندسون ، ولكل معمارية مختلفة حالة استخدام خاصة بها. من أهمها :

**الشبكات العصبية التلافيفية أو CNNs** ، هي بنية الشبكة العصبية المستخدمة بشكل شائع في إنشاء رؤية الكمبيوتر الأنظمة. تمكنهم بنية الشبكات العصبية التلافيفية من تفسير بيانات الصورة ، وتحويلها إلى أرقام يمكن لشبكة متصلة بالكامل تفسيرها. - تحتوي شبكة CNN على أربعة مكونات رئيسية:

❖ طبقات تلافيفية

❖ طبقات الاختزال / التجميع

❖ وظائف التنشيط

❖ طبقات متصلة بالكامل

الطبقات التلافيفية هي ما يأخذ الصور كمدخلات في الشبكة ، وتحليل الصور والحصول على قيم البكسل. الاختزال أو التجميع هو المكان الذي يتم فيه تحويل أو تقليل قيم الصورة لتبسيط تمثيل الصور وتقليل حساسية مرشحات الصورة للضوضاء. تتحكم وظائف التنشيط في كيفية تدفق البيانات من طبقة إلى الطبقة التالية ، والطبقات المتصلة بالكامل هي التي تحلل القيم التي تمثل الصورة وتتعرف على الأنماط الموجودة في تلك القيم. (1 website)

## 12-3 النظم الهجينة Hybrid systems

مع تقدم المجتمع البحثي في مجال الذكاء الاصطناعي والتعلم العميق، يشعر العلماء بشكل متزايد بالحاجة إلى الانتقال نحو الذكاء الاصطناعي الهجين. يوصف الذكاء الاصطناعي الهجين بأنه القدرة على حل المشاكل الأساسية التي يواجهها التعلم العميق اليوم.

في الذكاء الاصطناعي، الذكاء الاصطناعي الرمزي هو مصطلح يطلق على مجموعة من جميع الأساليب في بحوث الذكاء الاصطناعي التي تستند إلى تمثيلات رمزية عالية المستوى (يمكن للبشر قراءتها) للمشاكل والمنطق والبحث.

استخدم الذكاء الاصطناعي الرمزي أدوات مثل البرمجة المنطقية وقواعد الإنتاج والشبكات الدلالية والأطر، وطور تطبيقات مثل الأنظمة القائمة على المعرفة (خاصة الأنظمة الخبيرة)

يجمع الذكاء الاصطناعي الهجين بين أفضل جوانب الشبكات العصبية والذكاء الاصطناعي الرمزي. ويتيح الجمع بين مجموعات البيانات الضخمة (المرئية والصوتية والنصية ورسائل البريد الإلكتروني وسجلات الدردشة وغيرها) للشبكات العصبية و استخراج الأنماط. بعد ذلك، يمكن لأنظمة الذكاء الاصطناعي القائمة على القواعد معالجة المعلومات المستخرجة باستخدام خوارزميات لمعالجة الرموز.

عند الجمع بين الذكاء الاصطناعي الرمزي والشبكات العصبية مع بعضهما البعض، يمكن أن يشكل الذكاء الاصطناعي الرمزي والشبكات العصبية قاعدة جيدة لتطوير أنظمة ذكاء اصطناعي هجينة، حيث يستخدم نموذج الذكاء الاصطناعي الهجين قدرة الشبكة العصبية على معالجة وتقييم البيانات غير المهيكلة مع استخدام تقنيات الذكاء الاصطناعي الرمزية. (website2)

## الفصل الرابع

### القسم العملي

#### 1-4 مقدمة

سننتقل في هذا الفصل الى طريقة العمل بما يحتويه من خوارزميات لمعالجة الصور قبل ادخالها للنظام و مخططات للشبكات التي تم دراستها وتدريبها على قاعدة البيانات الخاصة , وسنشرح كل خطوة تم تطبيقها في النظام الهجين

#### 2-4 مخطط العمل:

كما يبين الشكل (1-4) , مخطط العمل الأساسي للنظام الهجين الذي يحوي المراحل الأساسية والتي سيتم شرحها بالتفصيل



الشكل (1-4) مخطط العمل

1- قاعدة البيانات: الصور الملتقطة بالرنين لغدة البروستاتا بصيغة MHA (وهو تنسيق خاص للصور الطبية يُستخدم في مجموعة أدوات التجزئة والتسجيل)

2- معالجة أولوية : وهي تحويل الصور الى صيغة DICOM للدخال الى ماتلاب (هو معيار للاتصال وإدارة معلومات التصوير الطبي والبيانات ذات الصلة) وانتقاء الشريحة المناسبة وتطبيق خوارزمية الاقتصاص والدمج

3- فرز البيانات : فرز الحالات الى ورم حميد أو خبيث

4- خوارزمية التعلم الهجين : تتكون من deep learning + support vector machine/ Decision trees

وستم فيها مناقشة النظم الهجينة التي تم تدريبها واختبارها

5- تشخيص المرض : وهي خرج خوارزمية التعلم الهجين في ما إذا كان المريض شخص باصابته بسرطان بروتات او ورم حميد , وسيتم بناء الواجهة الرسومية الخاصة بتشخيص المرض

### 4-3 قاعدة البيانات

هي قاعدة البيانات التي تحميلها من مجموعة PI-CAI من موقع Grand challenge وكانت مجموعة البيانات تحوي 1500 حالة تم تصويرها بالرنين المغناطيسي ثنائي المعاملات (BpMRI) و ملف Excel يحوي بيانات توصيفية للحالات كل حالة تتكون من ما يلي :

1. صور شرائح T2 : زمن الاسترخاء العرضي ويرتبط بالتأثير المتبادل بين النوى بعضها ببعض, وهو الزمن اللازم لكي تتلاشى مركبة المغنطة العرضية للنوى المتعامدة مع اتجاه الحقل المغناطيسي المطبق, وتستخدم ال T2 عند الحاجة إلى إشارة عالية الكثافة من جزيئات الماء .

2. صور شرائح Diffusion-weighted imaging (DWI) : التصوير الموزون بالانتشار (DWI) هو شكل من أشكال التصوير بالرنين المغناطيسي يعتمد على قياس الحركة الحرة العشوائية لجزيئات الماء داخل الأنسجة. وبعبارة مبسطة عامة، تُظهر الأنسجة عالية الخلوية أو تلك التي بها تورم خلوي معاملات انتشار أقل. ويفيد الانتشار بشكل خاص في توصيف الورم ونقص التروية الدماغية.

3. صور شرائح apparent diffusion coefficient (ADC) : معامل الانتشار الظاهري (ADC) هو مقياس لحجم انتشار جزيئات الماء داخل الأنسجة، ويُحسب عادةً باستخدام التصوير بالرنين المغناطيسي مع التصوير المرجح بالانتشار (DWI). وهو يميّز حركة الماء التي تتم ملاحظتها في البيئة السريرية، مما يعكس الحدود التي لا يمكن فصل الانتشار النقي في الجسم الحي بسهولة عن المصادر الأخرى لحركة الماء.

4. صور اقنعة (Mask): وهي القناع الخاص بغدة البروستات حيث يتم تجزئة الغدة من الصور بشكل مباشر , وهي صورة ثنائية يتم ضربها بالصورة الاصلية لتجزئة البروستات.


\_ يعتبر تشخيص سرطان البروستات معقدا ولا يمكن الاعتماد على معامل واحد للتصوير (كال T2 مثلا) .

\_ ان البروتوكول العالمي لتصوير غدة البروستات هو تصوير عدة معاملات في نفس الوقت و هي (DCE)+(T2+DWI+ADC+T1(Axial)+Dynamic contrast enhanced) , بجمع كل انواع التصوير السابقة

يمكن تشخيص المرض بدقة باستخدام التصوير بالرنين المغناطيسي متعدد المعاملات (mp MRI) , ولكنها مكلفة جدا وان استخدام (DCE) تحتاج لحقن بمادة ظليلة اي تستغرق عملية التصوير وقتا طويلا .

\_ تحدي PI\_CAI هي مسابقة لايجاد افضل نموذج شبكة ذكاء اصطناعي قادرة على التشخيص من معاملات اقل والتي هي (T2+DWI+ADC) , باستخدام التصوير بالرنين المغناطيسي ثنائي المعاملات , والذي بدوره سيققل من التكلفة والوقت اللازم لعملية التصوير

## 4-4 معالجة الأولية للصور




الشكل (2-4) خوارزمية المعالجة الأولية

### 4-4-1 تحويل من صيغة MHA الى صيغة DICOM

ان MHA هو تنسيق خاص للصور الطبية يُستخدم في مجموعة أدوات التعزئة والتسجيل , لا يمكن ادخال هذه الصيغة على ماتلاب ومعالجتها , بالتالي نحول لصيغة DICOM (هو معيار للاتصال وإدارة معلومات التصوير الطبي والبيانات ذات الصلة) يدويا عن طريق برنامج 3D-slicer (وهو عبارة عن منصة معيارية مرنة لتحليل

الصور وتحويلها) , كما يبين الشكل (3-4)



الشكل (3-4) تطبيق 3D-slicer خلال عملية التحويل

#### 4-4-2 اختيار شرائح الورم من كل حالة

ان كل حالة تحتاج معاينة وتحليل لأنواع التصوير الثلاث (T2+DWI+ADC) لمعرفة مكان الورم بشكل دقيق , حيث قمنا سابقا بدراسة غدة البروستات والتواصل مع اخصائي اشعة لمعرفة و لفهم كيفية الانتقاء الصحيح للصور , حيث اعتمدنا على انتقاء الصور التي تحوي اكبر مساحة ورمية حميدة أو خبيثة .

#### 4-4-3 تجهيز الصور للتجزئة

بداية نريد ان تكون جميع الصور بنفس الحجم حتى يتم دمجها مع بعضها البعض وهذا شرط اساسي لعملية الضرب والدمج.

حيث ان صور T2 بحجم (640\*640\*1) وصور DWI بحجم (128\*120\*1) وصور ADC بحجم (128\*120\*1) وصور القناة (640\*640) ثنائية , كما يوضح الشكل (4-4)



الشكل (4-4) الصور قبل المعالجة للحالة رقم (21 وهي سرطانية) الصورة الأولى T2 , الصورة الثانية قناة البروستات, الصورة الثالثة ADC والصورة الرابعة DWI

بالتالي نقوم بتطبيق تعليمة {imresize} على الصورتين (DWI,ADC) لتعديل الحجم الى (640\*640) بالتالي تصبح جميع الصور من نفس الحجم .

نقوم باقتصاص الصورة حتى نخفف من العبء على الشبكة العصبونية , حتى نقوم بالاقتصاص نعلم أن غدة البروستات في البيانات ليست بالضرورة ان تكون في منتصف الصورة بالتالي نحتاج طريقة خاصة حتى نقوم بالاقتصاص بشكل صحيح شاملا كل الغدة في الصور الأربعة الجديدة.


بالتالي نقوم بتطبيق تعليمة استخراج خصائص الصورة { regionprops('table',gdicom,'Centroid')} حيث ان gdicom هي صورة القناع الثنائية, ونقوم باستخلاص خصائص مركز الغدة والتي تكون بكسل في منتصف الغدة بقيمتي سطر وعمود محددتين .

بعد تحديد مركز الغدة تم الاستعلام عن اكبر حجم لغدة البروستات ضمن البيانات وتحديد احداثيات اربع نقاط تأخذ شكل مربع بعيدة عن المركز مسافة (93 بكسل) والتي ستكون نقاط زوايا الصورة الجديدة

نقوم بتطبيق تعليمة {imcrop} على الصور الأربعة مع ادخال الأحداثيات السابقة لتنتج الصور المقتصة بحجم (187\*187).

**4-4-4 تجزئة القناع :** بعد اقتصاص الصور (T2+DWI+ADC+MASK) نقوم بتطبيق القناع على كل من

صور ADC , DWI , T2 وذلك بعملية الضرب , لتنتج الصور كما في الشكل (4-5)




الشكل (4-5) صور تجزئة القناع من اليمين الى اليسار صورة DWI , صورة ADC , صورة T2



#### 5-4-4 دمج الصور

حتى نخفف من العبء على الشبكة العصبونية نحتاج لدمج الصور الثلاث لتكون صورة واحدة ملونة , وذلك عن طريق تعليمة {imfuse} حيث ينشئ صورة ملونة RGB مركبة , حيث تُظهر المناطق الرمادية في الصورة المُركبة الأماكن التي تتطابق فيها الصورتان في الشدة. و تُظهر المناطق ذات الشدة مختلفة بشدة لونية تابعة للصورة ذات الشدة المختلفة. وتنتج لدينا الصورة الجديدة بحجم (187\*187\*3) كما في الشكل (4-6).




الشكل (4-6) صورة تطبيق الدمج للصور الثلاث على حالة ورم سرطاني ,  
تظهر اللون الزرقاء مكان الورم السرطاني وباقي المناطق السليمة تتشارك  
باللون الأحمر

يتم تطبيق الخوارزمية على جميع الصور و تحويلها الى صيغة PNG. ومن ثم تخزينها في ملف جديد للفرز (خوارزمية معالجة البيانات الأولية في الملحق A).

#### 5-4 تجهيز البيانات للتعلم

تم حذف الحالات التي تحوي اخطاء أو ضجيج عالي أو نقص في المعلومات المطلوبة والتي لا تصلح لعملية الكشف , قمنا بانتقاء 404 حالة جيدة لتكون دخل للشبكة العصبية , كما يبين الشكل (4-7) , و تم فرز الحالات الى ورم حميد

(benign tumor) وحالات خبيثة (cancer tumor) (180 حالة ورم خبيث \_ 224 حالة ورم حميد), حسب البيانات  
التوصيفية المرفقة للحالات .



الشكل (4-7) قاعدة البيانات بعد المعالجة الأولية للصور وتجهيز البيانات

بما ان النظام الهجين يقسم على مرحلتين للتدريب والاختبار قسمنا البيانات كالتالي:

\_ بالنسبة للمرحلة الأولى وهي شبكة تعلم عميق تم استخدام 260 حالة للتدريب (140 ورم حميد \_ 120 ورم خبيث)

\_ أما المرحلة الثانية وهي شبكة تعلم بالانحدار باحدى الشبكات (SVM , bagged trees , boosted trees) تم استخدام 304 (174 ورم حميد \_ 130 ورم خبيث) حالة للتدريب

اما حالات الاختبار هي 100 حالة (50 ورم حميد \_ 50 ورم خبيث) وسيتم تطبيق حالات الاختبار على خرج المرحلة الأولى (نظم التعلم العميق) وخرج المرحلة الثانية للمقارنه (النظم الهجينة)

## 4-6 النظام الهجين

بالنسبة للمرحلة الأولى قمنا بالتدريب على عدة من أهم قوالب الشبكات منها

( Resnet, Googlenet ) والتي تعتبر من انجح الأنظمة في التصنيف .

أما بالنسبة للمرحلة الثانية قمنا بتجربة عدة انظمة تعلم من (SVM , Boosted trees , Bagged trees)

#### 1-6-4 مخطط عمل النظام الهجين



الشكل (4-8) مخطط عمل النظام الهجين

#### 2-6-4 شبكات التعلم العميق


##### 1-2-6-4 شبكة (Res Network)

ResNet هو نموذج تعلم عميق تم إطلاقه في عام 2015 من قبل Microsoft Research لغرض التعرف البصري.

ResNet هي اختصار لكلمة "Residual Networks" وهي "الشبكات المتبقية"

تتكون البنية الكاملة لـ ResNet من أربعة أجزاء:

##### 1- طبقات الالتفاف (Convolution layers): تلعب هذه الطبقات دوراً أساسياً في استخراج السمات. يتضمن الالتفاف



تطبيق مرشحات على الصور المُدخلة وهذه المرشحات تقوم بإنشاء مصفوفة ثنائية الأبعاد من القيم التي تعبر عن السمة المستخرجة، كما يبين الشكل (4-9)، مما يسمح للنموذج باكتشاف الأنماط والحواف والأنسجة المختلفة داخل البيانات.

يتم استخدام مرشحات متعددة، حيث تؤدي المصفوفات المختلفة التي أنشأت من المرشحات المختلفة إلى استخلاص تمثيلات أكثر تعقيداً "أعمق" وتتراوح أعداد المرشحات من (32 إلى 2048)

الشكل (4-9) عمل طبقة التلافيف في استخلاص المميزات

2- كتل التلافيف: تتألف هذه الكتل من طبقات التلافيف المتعددة , وهي تساعد في استخراج الميزات عالية المستوى من بيانات الإدخال.، كل كتلة تلافيف تتألف من :


- طبقة تلافيف (Convolution layers)
- تطبيع دفعي (Batch Normalization)
- دالة تنشيط (Relu)

التطبيع الدفعي (Batch Normalization) : التطبيع هو أداة معالجة مسبقة للبيانات تُستخدم لتحويل البيانات الرقمية إلى مقياس مشترك دون تشويه شكلها, وهي تساعد في تسريع تدريب الشبكة ومنع الشبكة من الوصول إلى Over Fitting (هي الحالة عندما تكون الشبكة قادرة على تصنيف بيانات التدريب ولكن غير قادرة على تصنيف أي بيانات خارج بيانات التدريب)


وتتم بإضافة طبقة جديدة في الشبكة بعد طبقة التلافيف , تقوم الطبقة الجديدة بإجراء عمليات التوحيد والتطبيع على مخرجات الطبقة السابقة بدفعات متلاحقة.

دالة التنشيط : يمكن تعريف دالة التنشيط على أنها دالة رياضية تُدخل اللاخطية على الشبكة العصبية. وهذا يمكن النماذج من تعلم الأنماط المعقدة ويساعدها على إجراء تنبؤات دقيقة , كما يبين الشكل (4-10)

إذا كانت المدخلات أعلى من عتبة معينة , فإن الخلية العصبية ستنشط , وإذا كانت أقل ستبقى غير نشطة , من خلال إدخال التحويلات غير الخطية في الشبكة, تساعد دوال التنشيط في إنشاء حدود قرار أكثر تقدمًا وتعقيدًا. وهذا يؤدي إلى تحسين الدقة والقدرات التنبؤية.



Neural Network without  
an Activation Function




Neural Network with  
an Activation Function

الشكل (4-10) تأثير دالة التنشيط على الشبكة العصبية

دالة التنشيط (Relu) : ReLU هي دالة التنشيط الأكثر شيوعًا والأكثر استخدامًا. فهي تسمح بمرور القيمة المُدخلة إذا كانت موجبة أو تُرجع صفرًا في حال كانت القيمة سالبة مما يقلل من مشكلة تلاشي التدرج الاشتقاقي (عندما يقترب مشتق دالة التنشيط من الصفر).

تُستخدم ReLU بشكل رئيسي في الطبقات المخفية للشبكة العصبية لأنها تجلب التقارب في البيانات. وهذا يعني أن ReLU قادرة على تنشيط مجموعة فرعية فقط من الخلايا العصبية بشكل انتقائي وتعيين جميع القيم الأخرى إلى الصفر. وهذا يؤدي إلى تمثيل أكثر كفاءة للبيانات عالية الأبعاد, كما يبين الشكل (4-11) شكل دالة التنشيط Relu




الشكل (4-11) دالة تنشيط Relu

3- الكتل المتبقية: هي كتلة بسيطة تعمل على إعادة جمع الدخل بالخرج, وتتكون من طبقة تلافيف واحدة بحجم نافذة ترشيح (1\*1) وذلك للحفاظ على حجم المرشحات ويتبعها طبقة تطبيع تعمل الكتل المتبقية كاختصارات أو وصلات تخطي تسمح للنموذج بتخطي طبقة أو أكثر. يساعد ذلك في التخفيف من مشكلة تلاشي التدرج الاشتقاقي , أثناء التدريب ويساعد في التدفق السلس للمعلومات.

4- الطبقة المتصلة بالكامل (Flatten/fully connected layer): إن خطوة التسطيح هي خطوة بسيطة في بناء شبكة وهي تتضمن أخذ خريطة السمات المجمعة التي تم إنشاؤها في خطوة التجميع وتحويلها إلى متجه أحادي البعد.



فيما يلي تمثيل مرئي لما تبدو عليه هذه العملية في الشكل (4-12)، حيث أن هذه الطبقات مسؤولة عن إجراء التنبؤات بناءً على الميزات المستخرجة. في سياق ResNet، تقوم الطبقات المتصلة بالكامل بتعيين الميزات المكتسبة إلى فئات المخرجات النهائية.




الشكل (4-12) عمل طبقة التسطيح

### -معمارية و مبدأ عمل شبكة Res\_Network

1-الدخل : بداية يتم تخزين الصور بتعليمة {imageDatastore} وهي تعليمة تخزن الصور مع حفظ تصنيف كل حالة، ثم تدخل البيانات الى طبقة التلافيف بنافذة (7\*7) وعدد مرشحات 64 (أن عدد المرشحات يمثل عدد العصبونات في هذه الطبقة) مع تطبيق padding بقيمة (3\*3) وهي عملية تقوم بزيادة ثلاث أسطر وثلاث أعمدة على الصورة (موجوده ضمن بارمترات طبقة التلافيف)، حيث أن تطبيق طبقة التلافيف تؤدي لأنقاص حجم الصورة ، بالتالي ضياع المعلومات (البكسلات) في أطراف الصورة ، أن خرج أول طبقة تلافيف (94\*94\*64)

بعدها نقوم بعملية التطبيع بدفعة واحدة ، ثم تطبيق دالة التنشيط Relu ، يتبعها طبقة Max pooling بحجم (3\*3) وظيفته هذه الطبقة هي تطبيق نافذة ترشيح بحجم (3\*3) وإيجاد أعلى قيمة ضمن النافذة وتعويضها في مصفوفة جديدة حجمها (47\*47\*64) ، كما يبين الشكل (4-13)




الشكل (4-13) دخل الشبكة

## 2- القالب المكرر:

أصبح لدينا 64 مصفوفة بحجم (47\*47) من الخطوة السابقة والذي سيتم إدخاله الى قالب يتم تكراره 16 مره , كما يبين الشكل (4-14) تنقسم الشبكة الى مسارين تحدثنا عنهم سابقا :

المسار الأول : وهي كتل التلافيف حيث تتكون من ثلاث كتل تلافيف حيث أول كتلة تكون حجم النافذه فيها (1\*1) بعدد مرشحات 64 وثاني كتلة تكون حجم النافذه (3\*3) بعدد مرشحات 64 وثالث كتلة حجم نافذه (1\*1) بعدد مرشحات 256 , محافظا على حجم الصورة (47\*47) و تصبح عدد المصفوفات 256 في خرج المسار الأول



المسار الثاني : وهي الكتل المتبقية التي تحدثنا عنها سابقا والتي تميز شبكة Resnet, حيث يتم اضافة طبقة تلافيف واحدة بحجم نافذه (1\*1) وعدده مرشحات 256 لتحافظ على حجم المصفوفة (47\*47) وبعدد مرشحات 256


حتى يتم جمع مسارين يشترط أن تكون البيانات في المسارين متشابهان بالحجم وعدد المصفوفات

يتم تكرار هذا القالب 16 مره بالتسلسل لزيادة عمق التدريب واستخراج السمات المعقدة من الأورام الحميدة والخبيثة

الشكل (4-14) من اليمين المسار الأول , ومن اليسار المسار الثاني



## -الخرج:



يوضح الشكل (4-15) المسار النهائي للشبكة , خلال ال 16 تكرار للقالب السابق يتم تقليل حجم المصفوفات وذلك خلال استخراج الميزات العميقة الى (6\*6) بعدد 2048 , اي يعني وجود 2048 ميزة تم استخراجها بحجم (6\*6) في هذا المسار تطبق طبقة Average pooling وهي طبقة تقوم بانتقاء القيمة المتوسطة من كل مصفوفة ليصبح حجم المصفوفة (1\*1)

وبعد نقوم بالادخال الى الطبقة المتصلة بالكامل (طبقة التسطيح) والتي شرحناها مسبقا ويليه دالة sigmoid التي تقوم بادراج القيم ضمن مجال [0,1] , بتحديد ان اي قيمة أعلى من 0.5 هي ورم حميد , وأي قيمة أقل من 0.5


هي ورم خبيث

الشكل (4-15) مسار الخرج النهائي للشبكة

(أن طبقة الخرج في شبكة Google net هي SoftMax تم ازلتها واضافة طبقة sigmoid للخرج لأن البيانات ثنائية أما 0 أو 1)

## -تدريب الشبكة Resnet


كما ذكرنا سابقا تم التدريب على 260 حالة بعدد تكرارات 140 تكرار وفي كل تكرار يتم تعديل الأوزان حتى الوصول الى دقة تدريب 100% (وهي اختبار حالات التدريب في كل تكرار فيما اذا كانت القيمة المتوقعة تساوي القيمة الحقيقية) كما في الشكل (4-16) , مع تحديد معدل التعلم (0.001)



الشكل (4-16) منحنى التدريب لشبكة Resnet, يرمز اللون الأزرق الى دقة التدريب ويرمز اللون الأسود الى دقة الاختبار

ملاحظة : أن دقة الاختبار في الشكل (4-16) منخفضة لأنه تم تحديد بيانات للاختبار فقط 20 حالة خلال التدريب , وتم تعديل عدد بيانات الاختبار الى 100 كما ذكرنا سابقا , وسيتم ارفاق الخوارزمية الخاصة بالاختبار في الملحق

منحنى معدل الخسارة : هو مقياس لأداء نموذج التعلم الآلي، وخاصة في مجال الشبكات العصبونية. يمثل معدل الخسارة متوسط الخطأ الذي يرتكبه النموذج في مهمة معينة، مثل تصنيف الصور أو التنبؤ بالبيانات , كما يبين الشكل (4-17)



الشكل (4-17) منحنى معدل الخسارة لشبكة Resnet, يرمز اللون الأحمر لمعدل الخسارة في بيانات التدريب ويرمز اللون الأسود الى معدل الخسارة لبيانات الاختبار


#### 4-2-6-2 شبكة التعلم العميق (Google Network)

وهي عبارة عن شبكة عصبية تلافيفية عميقة طورها باحثون من شركة Google , تم تقديم بنية GoogLeNet في مسابقة ImageNet للتعرف البصري عام 2014 (ILSVRC14) لحل مهام الرؤية الحاسوبية مثل تصنيف الصور واكتشاف الأجسام

#### - معمارية ومبدأ عمل شبكة (Google net)

1- الدخول: يتم ادخال الصورة ذات الحجم  $(3 \times 187 \times 187)$  الى طبقة تلافيف بحجم نافذة  $(7 \times 7)$  و بعدد مرشحات 64 و يتبعها دالة Relu , ليكون خرج هذه الطبقة  $(64 \times 94 \times 94)$  , ومن ثم يليها طبقة Max pooling بحجم نافذة  $(3 \times 3)$  تقوم بايجاد اعلى قيمه ضمن مصفوفة الطبقة وادخالها في المصفوفة الجديدة ليصبح خرج الطبقة  $(64 \times 47 \times 47)$  , بعدها يتم تطبيع البيانات.


الطبقة التي تليها هي طبقة تلافيف بحجم نافذة  $(1 \times 1)$  وعدد مرشحات 64 , يليها ايضا طبقة تلافيف بحجم نافذة  $(1 \times 1)$  بعدد مرشحات 192 و ثم تطبيع, وفي النهاية Max pooling بحجم نافذة  $(3 \times 3)$  ليكون خرج مسار الدخول  $(192 \times 24 \times 24)$  , كما يوضح الشكل (4-18).



الشكل (4-18) مدخل شبكة Google net

اي 192 مصفوفة حجم كل مصفوفة (24\*24)

2- **القالب المكرر:** سمي بالقالب لأنه يتم تكراره 10 مرات على التوالي لزيادة عمق التدريب واستخراج ميزات أعمق, حيث يقسم الى اربع مسارات يطبق في كل مسار كتل تلافيف بمعاملات معينة لتحافظ على حجم المصفوفة مع زيادة عدد المرشحات, كما يبين الشكل (4-19), بعد تطبيق تكرار القالب يكون حجم الصورة (6\*6) وعدد المرشحات 1024.



الشكل (4-19) القالب المكرر

### 3- الخرج:


بعد انا اصبح حجم المصفوفة (6\*6\*1024) يتم الادخال لطبقة

Avarege pooling لايجاد القيمة الوسطى وتعويضها في المصفوفة الجديدة

, يليها طبقة متصلة بالكامل Flatten ثم طبقة Sigmoid للتصنيف

(أن طبقة الخرج في شبكة Google net هي SoftMax تم ازلتها واضافة


طبقة sigmoid للخرج لأن البيانات ثنائية أما 0 أو 1)



الشكل (4-20) الخرج

## Google Network تدريب شبكة


تم التدريب على 260 حالة بعدد تكرارات 100 تكرار وفي كل تكرار يتم تعديل الأوزان حتى الوصول الى دقة تدريب 100% (وهي اختبار حالات التدريب في كل تكرار فيما اذا كانت القيمة المتوقعة تساوي القيمة الحقيقية) كما في الشكل (16-4) , مع تحديد معدل التعلم (0.001)



الشكل (21-4) منحنى التدريب لشبكة Googlenet , يرمز اللون الأزرق الى دقة التدريب ويرمز اللون الأسود الى دقة الاختبار

ملاحظة : أن دقة الاختبار في الشكل (21-4) أيضا منخفض بسبب انه تم تحديد بيانات للاختبار فقط 20 حالة خلال التدريب , وتم تعديل عدد بيانات الاختبار الى 100 كما ذكرنا سابقا , وسيتم ارفاق الخوارزمية الخاصة بالاختبار في الملحق

أما منحنى معدل الخسارة , كما يبين الشكل (22-4)



الشكل (22-4) منحنى معدل الخسارة لشبكة Googlenet , يرمز اللون الأحمر لمعدل الخسارة في بيانات التدريب ويرمز اللون الأسود الى معدل الخسارة لبيانات الاختبار

### 3-2-6-4 نتائج الاختبار للشبكتين

| matrix       |            |   |   |
|--------------|------------|---|---|
| 100x2 double |            |   |   |
|              | 1          | 2 | 3 |
| 1            | 0.9994     | 1 |   |
| 2            | 0.9966     | 1 |   |
| 3            | 0.9769     | 1 |   |
| 4            | 0.9979     | 1 |   |
| 5            | 0.0060     | 1 |   |
| 6            | 1.0000     | 1 |   |
| 7            | 1.0000e-03 | 0 |   |
| 8            | 0          | 0 |   |
| 9            | 0          | 0 |   |
| 10           | 0.0066     | 0 |   |
| 11           | 0.0018     | 0 |   |
| 12           | 0.0059     | 0 |   |
| 13           | 0          | 0 |   |
| 14           | 0.0030     | 0 |   |
| 15           | 0.0080     | 0 |   |
| 16           | 0.0000     | 0 |   |

تم اختبار النموذجين بعدد بيانات اختبار 100 حالة مختارة , تم حساب دقة وحساسية وخصوصية كل نظام , حيث تم بناء مصفوفة من 100 سطر وعمودين , وأدخل بالعمود الأول القيم التي تم التنبأ بها من قبل النظام وذلك باستدعاء النظام ضمن حلقة {for} لحساب خرج كل الحالات , أما العمود الثاني يحوي القيم الحقيقية للحالات (0 أو 1) , حيث يرمز (1) لوجود ورم خبيث و (0) لوجود ورم حميد , كما يبين الشكل (4-23) .

- تم قياس أداء تصنيف النظم باستخدام مصفوفة الارتباك

مصفوفة الارتباك confusion matrix : مصفوفة الارتباك هي تقنية قياس الأداء لتصنيف التعلم الآلي , وهو عبارة عن جدول يساعدك على معرفة أداء نموذج التصنيف على مجموعة من البيانات الاختبارية حتى يتم معرفة القيم الحقيقية.


الشكل (4-23) مصفوفة تحوي القيم التي تم التنبأ بها من قبل النظام, والقيم الحقيقية

يتم ذلك بحساب كل من TP (عدد الحالات الايجابية الصحيحة) , TN (عدد

الحالات السلبية الصحيحة) , FP (عدد الحالات الايجابية الخاطئة) , FN (عدد

الحالات السلبية الخاطئة) , بشرط ان الورم الخبيث يكون تنبأه بقيمة أعلى من 0.5 والورم الحميد اقل من 0 , كما يبين

الشكل (4-24)



الشكل (4-24) مصفوفة الارتباك

والتي من خلال مصفوفة الارتباك يتم حساب كل من :

- دقة النظام Accuracy : وهي مدى قدرة النظام جميع الحالات الايجابية والسلبية بالنظام

$$\text{Accuracy} = (\text{TP} + \text{TN}) / (\text{TP} + \text{TN} + \text{FP} + \text{FN})$$

- الحساسية Sensitivity : تقيس مدى قدرة الاختبار على اكتشاف جميع الحالات الإيجابية. يتم حساب الحساسية بقسمة عدد النتائج الإيجابية الحقيقية على العدد الإجمالي للحالات الإيجابية (والتي تشمل النتائج الإيجابية الكاذبة).

$$\text{Sensitivity} = (\text{TP}) / (\text{TP} + \text{FN})$$

- الخصوصية Specificity : تقيس جودة تصنيف اختبارنا للحالات السلبية على أنها حالات سلبية. يتم احتساب النوعية بقسمة عدد النتائج السلبية الحقيقية على إجمالي عدد الحالات السلبية (التي تتضمن حالات سلبية كاذبة).

$$\text{Specificity} = \text{TN} / (\text{TN} + \text{FP})$$

- الخوارزمية الخاصة بحساب مصفوفة الارتباك و الدقة والحساسية والخصوصية في الملحق C

يبين الجدول التالي دقة وحساسية وخصوصية شبكتي التعلم العميق Resnet و Googlenet

| Google Network                                 | Res Network                                 |                     |
|------------------------------------------------|---------------------------------------------|---------------------|
| <b>Tp= 32 , Tn=35</b><br><b>Fp= 15 , Fn=18</b> | <b>Tp= 44 , Tn=47</b><br><b>Fp=3 , Fn=6</b> | قيم مصفوفة الارتباك |
| <b>67%</b>                                     | <b>91%</b>                                  | دقة النظام          |
| <b>64%</b>                                     | <b>88%</b>                                  | حساسية النظام       |
| <b>70%</b>                                     | <b>94%</b>                                  | خصوصية النظام       |

نلاحظ أن دقة شبكة Resnet أعلى بكثير من شبكة Googlenet في تشخيص الأورام الخبيثة و الأورام الحميدة

خوارزمية شبكة Resnet في الملحق B

#### 3-6-4 معالجة البيانات التوصيفية

في هذه المرحلة سيتم تحضير البيانات الخاصة بنظم تحليل الأنحدار , حيث تم جمع نتائج شبكة التعلم العميق و المتغيرات الوصفية والتحليلية ضمن مصفوفة واحدة كما يبين الشكل (4-25) , أعمدها بالترتيب :

1- خرج شبكة التعلم العميق : وتكون فيها القيم عشرية بمجال [0,1] حيث أن أي قيمة أعلى من 0.5 هي تنبأ للنظام

بأن الورم خبيث وأي قيمة أقل من 0.5 هي تنبأ بوجود ورم حميد



2- عمر المريض : ان سرطان البروستات يتعلق بعمر المريض , كلما كان المريض أكبر سنا كلما كانت احتمالية اصابته بمرض السرطان اكبر

3- الواسم الورمي أو المستضد النوعي PSA : هو عبارة عن بروتين سكري يصنع من قبل البروستات بالحالة الطبيعية ولكن زيادة ارتفاعه عن الحد الطبيعي يؤدي الى زيادة احتمالية الاصابة بالسرطان في غدة (تم شرحه سابقا في الصفحة 22 (بروتوكول التشخيص))

4- حجم البروستات : ان تضخم البروستات يتعلق بوجود ورم حميد أو خبيث

5- PSAD : وهو نوع من دمج ما بين حجم البروستات والمستضد النوعي لزيادة دقة التحليل

6- الخرج الحقيقي للحالات : وهذا العمود سيتم ادخاله من قبل تطبيق Regression learner في Matlab على أنه الخرج الخاص بالنظام .

خوارزمية المصفوفة في الملحق D

|    | 1          | 2  | 3       | 4       | 5      | 6 |
|----|------------|----|---------|---------|--------|---|
| 1  | 0.9987     | 60 | 7.7000  | 55      | 0      | 0 |
| 2  | 2.9237e-07 | 64 | 8.7000  | 102     | 0.0900 | 0 |
| 3  | 5.8468e-04 | 58 | 4.2000  | 74      | 0.0600 | 0 |
| 4  | 5.3773e-06 | 72 | 13      | 71.5000 | 0      | 0 |
| 5  | 1.9007e-04 | 67 | 8       | 78      | 0.1000 | 0 |
| 6  | 0.9995     | 65 | 14.1000 | 51      | 0.2400 | 1 |
| 7  | 2.3633e-04 | 73 | 6.2000  | 27      | 0.1000 | 0 |
| 8  | 0.0061     | 68 | 3.8300  | 41      | 0.0900 | 0 |
| 9  | 0.9999     | 81 | 11.1000 | 56      | 0.2000 | 1 |
| 10 | 1.8480e-05 | 65 | 24      | 120     | 0      | 0 |
| 11 | 0.0136     | 67 | 6.1900  | 76      | 0.0800 | 0 |
| 12 | 0.2671     | 60 | 7.1000  | 34      | 0      | 0 |
| 13 | 0.2133     | 64 | 9.9000  | 70      | 0.2400 | 1 |
| 14 | 3.5093e-04 | 48 | NaN     | 62      | 0.0700 | 0 |
| 15 | 0.0446     | 60 | 8.5000  | 71      | 0.1300 | 0 |

الشكل (4-25) مصفوفة دخل نظم الانحدار

#### 4-6-4 شبكات التعلم بالانحدار


الانحدار هو قياس إحصائي يحاول تحديد قوة العلاقة بين متغير تابع واحد وسلسلة من المتغيرات الأخرى.

أما الشبكات تعلم بالانحدار نوع تعلم المشرف عليه يستخدم لنمذجة العلاقة بين المتغير التابع وواحد أو أكثر من المتغيرات المستقلة، مما يتيح التنبؤ واتخاذ القرار والرؤى عبر مختلف المجالات

## Regression learner برنامج 1-4-6-4

وهو تطبيق ضمن ماتلاب يقوم بتدريب نماذج الانحدار للتنبؤ بالبيانات , يقوم هذا التطبيق باستكشاف البيانات وتحديد الميزات وتدريب النماذج وتقييم النتائج. يمكن من خلاله إجراء تدريب آلي للبحث عن أفضل نوع من نماذج الانحدار، بما في ذلك نماذج الانحدار الخطي (linear regression)، وأشجار الانحدار (regression trees)، ونماذج الانحدار الغاوسي (Gaussian process regression)، وآلات دعم المتجهات (support vector machines)، ومجموعات أشجار الانحدار (ensembles of regression trees).

يتم إجراء التعلم الآلي الخاضع للإشراف من خلال توفير مجموعة معروفة من الملاحظات لبيانات المدخلات (المتنبئات) والاستجابات المعروفة (تشخيص الحالة) , يوضح الشكل (4-26) واجهة التطبيق.




الشكل (4-26) واجهة تطبيق Regression learner

\_ من خلال التدريب على مصفوفة المدخلات السابقة للشبكتين (Resnet, Googlenet) (أي بتغيير قيم أول عمود فقط حسب خرج هاتين الشبكتين) , وجدنا ثلاث نظم انحدار ذات معدل خطأ منخفض في التصنيف (نظامين من نوع أشجار القرار ونظام آلة دعم المتجهات) حققوا أعلى دقة في التصنيف للمدخلات وسنقوم بشرح مبدأ عملهم

#### 4-6-2 أشجار القرار Decision trees

أشجار القرار، والمعروفة أيضًا باسم نماذج أشجار التصنيف والانحدار (CART)، وهي طرق قائمة على التعلم الآلي الخاضع للإشراف. تعتبر أشجار التصنيف البسيطة وأشجار الانحدار سهلة الاستخدام والتفسير، ولكنها لا تتنافس أفضل طرق التعلم الآلي. ومع ذلك، فهي تشكل الأساس للنماذج المجمعّة مثل الأشجار المجمعّة (bagged trees) والغابات العشوائية (random forests) والأشجار المعززة (boosted trees)، والتي على الرغم من أنها أقل قابلية للتفسير، إلا أنها دقيقة للغاية.



الشكل (4-27) مبدأ عمل شجرة القرار

تتفرع هذه النماذج إلى عقد طرفية غير متداخلة (أوراق)، حيث توصف كل عقدة بمجموعة من القواعد التي يمكن استخدامها للتنبؤ باستجابات جديدة، القيمة المتوقعة لكل عقدة هي المنوال (التصنيف) أو المتوسط (الانحدار).

حسب الشكل (4-27)، أن النقاط الخضراء تعبر عن التصنيف الأول، والنقاط الحمراء تعبر عن التصنيف الثاني، تقوم شجرة القرار بالبدء بعقدة واحدة تحوي معلومات أحداثيات النقاط الحمراء والخضراء


تتفرع هذه النماذج إلى عقد طرفية غير متداخلة (أوراق)، حيث توصف كل عقدة بمجموعة من القواعد التي يمكن استخدامها للتنبؤ باستجابات جديدة.

حيث من خلال هذه التفرعات (من الأعلى للأسفل)، في الحالة المثالية تقوم شجرة القرار بعزل أحد بيانات التصنيفين (النقاط الحمراء) حتى تصل لعقدة تحوي بيانات التصنيف الآخر بالكامل (النقاط الخضراء فقط)، وبالتالي يتم التدريب.

يتدرب النظام حتى يصل لأفضل تقسيم لشجرة القرار هو بالاعتماد على المتغير المتنبئ ونقطة القطع التي تقلل من دالة التكلفة , حيث أن دالة التكلفة الأكثر شيوعاً لأشجار الانحدار هي مجموع المربعات المتبقية (R-squard) .


تقوم أشجار القرار بتكرار عملية التقسيم لكل عقدة فرعية حتى يتم استيفاء معيار التوقف، عندما لا يؤدي استمرار التقسيم إلى تحسين النموذج بشكل كبير , وعند ادخال قيمة جديدة الى النظام يتم التصنيف بعزل هذه القيمة حسب القواعد الموضوعه.

-نظم اشجار التجميع **bagging trees**: هو نوع من أنواع أشجار القرار تعتمد فيها على تقسيم البيانات بشكل متساوي بتقنية تسمى **boostrabing** (التعزيز) كل فرع يحوي في نهايته على مصنف (classifier) وكل فرع مستقل بشكل كامل عن باقي الأفرع, وعند تدريب النظام لا يتم أسناد أوزان , وعند الاختبار ينتقي النظام التصنيف الأكثر توقعاً من بين كل التصنيفات , كما يبين الشكل (4-28),



الشكل (4-28) مبدأ عمل اشجار التجميع


-نظام الأشجار المعززه **(boosted trees)** : هو نوع من أشجار القرار الذي يقوم بداية بتصنيف كامل البيانات بدون تقسيم , عند أظهار ناتج التصنيف لأول دورة يقوم النظام باسناد اوزران الى البيانات التي لم يتم تصنيفها بشكل صحيح وترك البيانات التي صنفتم بشكل صحيح دون أسناد وزن حتى تشمل الدورة اللاحقة على الانتباه للبيانات التي لم تصنف بشكل صحيح , ويتم تكرار هذه العملية حتى الوصول الى اقل نسبة خطأ , كما يوضح الشكل (4-29)



الشكل (4-29) مبدأ عمل الأشجار المعززة

#### 4-6-3 آلة دعم المتجهات support vector machines :

يعتبر SVM من أبسط نظم التعلم وأكثرها نجاحاً حيث تقوم بتمثيل البيانات في فضاء حالة اما ثنائي او ثلاثي البعد , تقوم SVM بإيجاد أفضل خط فصل يمكن من فصل تصنيفين عن بعضهما البعض , ان النقاط التي تكون قريبة من خط الفصل تسمى , بنقاط المتجه الداعم , ويتم التدريب حتى إيجاد أفضل خط فصل لتصنيفين او أكثر, كما يبين الشكل (4-30)



الشكل (4-30) مبدأ عمل SVM


#### 4-6-4 نتائج النظام الهجين

تم اختبار النظم بنفس بيانات الاختبار التي اختبرت بها شبكتي التعلم العميق سابقا , تم ايجاد قيم مصفوفة الارتباك وحساب الدقة والحساسية والخصوصية لكل نظام , يوضح الجدول التالي نتائج النظم الهجينة

| Google Network                 |                                |                             | Res Network                       |                                |                             |          |
|--------------------------------|--------------------------------|-----------------------------|-----------------------------------|--------------------------------|-----------------------------|----------|
| أشجار التجميع<br>Bagging trees | أشجار المعززة<br>Boosted trees | اللة دعم<br>المتجهات<br>SVM | أشجار التجميع<br>Bagging<br>trees | أشجار المعززة<br>Boosted trees | اللة دعم<br>المتجهات<br>SVM |          |
| 85%                            | 87%                            | 80%                         | 95%                               | 97%                            | 91%                         | الدقة    |
| 86%                            | 88%                            | 77%                         | 96%                               | 96%                            | 89%                         | الحساسية |
| 84%                            | 86%                            | 83%                         | 94%                               | 98%                            | 93%                         | الخصوصية |



## 7-4 تشخيص المرض



الشكل (31-4) الواجهة الرسومية

من الجدول السابق نجد أن نظام (Resnet+Boosted trees) هو النظام الأكثر نجاحاً بين الأنظمة الستة حيث أنه قادر على كشف الحالات الصحيحة بدقة (97%) وقادر على تشخيص الأورام السرطانية بدقة (96%) و تشخيص الأورام الحميدة بدقة (98%) بالتالي تم اختيار هذا النظام الهجين لتشخيص المرض و تطبيقه ضمن واجهة رسومية لكي يستطيع الطبيب تشخيص الحالات المدخلة , توضح الصورة (31-4) الواجهة الرسومية المستخدمة

حيث يتم تحميل الصور الخاصة بالحالة (T2,DWI,ADC,Mask) ومن ثم يتم معالجة البيانات وإظهار الصورة الملونة (Colored Image) الناتجة من زر (process the images) , ثم يقوم المستخدم بإدخال المعلومات الوصفية في قسم (Patient Descriptive Information) وهي المعلومات المذكورة سابقاً

(Patient Age , PSA , PSAD, Prostate Volume) وإظهار تشخيص المرض في قسم (The Final Result) , عن طريق زر (Diagnose The Patient's Condition) ليظهر الناتج في المربع الأبيض فيما إذا كان المريض مصاب بورم سرطاني أم ورم حميد (patient's condition) وإظهار نواتج التشخيص الخاصة من التعلم العميق (deep learning diagnose)

و النظام الهجين (Hybrid System Diagnose) , الكود الخاص ببناء الواجهة الرسومية في الملحق E

## 4-8 المقترحات والتوصيات

نهدف مستقبلا ل:

- I. رفع كفاءة نظم التعلم العميق (Resnet , Googlenet) بزيادة عدد الحالات الى 700 حالة .
- II. رفع كفاءة نظم التعلم بالانحدار بزيادة عدد البيانات التوصيفية وذلك باستخراج الواصفات الخاصة بصور DWI والتي تصل ل 25 واصفة يتم ادخال هذه الواصفات الى نظم التعلم بالانحدار للتدريب ورفع كفاءة النظام الهجين
- III. انشاء تطبيق مستقل من ماتبلاي يمكن تحميله على اي حاسب , وذلك للمساعدة على اتخاذ القرار الطبي
- IV. نشر مقالة بعد تطبيق المقترحات السابقة وذلك بمساعدة الدكتور المشرف محمد داعر .

## المراجع

- [1] Eklund, M., Jäderling, F., Discacciati, A., Bergman, M., Annerstedt, M., Aly, M., ... & Nordström, T. (2021). MRI-targeted or standard biopsy in prostate cancer screening. *New England Journal of Medicine*, 385(10), 908-920.
- [2] Epstein, J. I., Amin, M. B., Reuter, V. E., & Humphrey, P. A. (2017). Contemporary Gleason grading of prostatic carcinoma: an update with discussion on practical issues to implement the 2014 International Society of Urological Pathology (ISUP) consensus conference on Gleason grading of prostatic carcinoma. *The American journal of surgical pathology*, 41(4), e1-e7
- [3] Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., & Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *nature*, 542(7639), 115-118.
- [4] Gupta, R. T., Spilseth, B., & Froemming, A. T. (2016). How and why a generation of radiologists must be trained to accurately interpret prostate mpMRI. *Abdominal Radiology*, 41, 803-804
- [5] Johnson, L. M., Turkbey, B., Figg, W. D., & Choyke, P. L. (2014). Multiparametric MRI in prostate cancer management. *Nature reviews Clinical oncology*, 11(6), 346-353.
- [6] Litwin, M. S., & Tan, H. J. (2017). The diagnosis and treatment of prostate cancer: a review. *Jama*, 317(24), 2532-2542.
- [7] McKinney, S. M., Sieniek, M., Godbole, V., Godwin, J., Antropova, N., Ashrafian, H., ... & Shetty, S. (2020). International evaluation of an AI system for breast cancer screening. *Nature*, 577(7788), 89-94.
- [8] Miller, K. D., Nogueira, L., Mariotto, A. B., Rowland, J. H., Yabroff, K. R., Alfano, C. M., ... & Siegel, R. L. (2019). Cancer treatment and survivorship statistics, 2019. *CA: a cancer journal for clinicians*, 69(5), 363-385
- [9] Reinke, A., Tizabi, M. D., Sudre, C. H., Eisenmann, M., Rädtsch, T., Baumgartner, M., ... & Maier-Hein, L. (2021). Common limitations of image processing metrics: A picture story. *arXiv preprint arXiv:2104.05642*.
- [10] Rosenkrantz, A. B., Oto, A., Turkbey, B., & Westphalen, A. C. (2016). Prostate Imaging Reporting and Data System (PI-RADS), version 2: a critical look. *American Journal of Roentgenology*, 206(6), 1179-1183.
- [11] Saha, A., Hosseinzadeh, M., & Huisman, H. (2021). End-to-end prostate cancer detection in bpMRI via 3D CNNs: effects of attention mechanisms, clinical priori and decoupled false positive reduction. *Medical image analysis*, 73, 102155.
- [12] Spilseth, B., Ghai, S., Patel, N. U., Taneja, S. S., Margolis, D. J., & Rosenkrantz, A. B. (2018). A comparison of radiologists' and urologists' opinions regarding prostate MRI reporting: results from a survey of specialty societies. *American Journal of Roentgenology*, 210(1), 101-107.
- [13] Steiger, P., Thoeny, H.C.(2016). Prostate MRI based on PI-RADS version 2: how we review and report. *Cancer Imaging* 16, 9. <https://doi.org/10.1186/s40644-016-0068-2>
- [14] Turkbey, B., Rosenkrantz, A. B., Haider, M. A., Padhani, A. R., Villeirs, G., Macura, K. J., ... Weinreb, J. C. (2019). Prostate Imaging Reporting and Data System Version 2.1: 2019 Update of Prostate Imaging Reporting and Data System Version 2. *European Urology*. doi:10.1016/j.eururo.2019.02.033

- [15] van Leeuwen, K. G., Schalekamp, S., Rutten, M. J., van Ginneken, B., & de Rooij, M. (2021). Artificial intelligence in radiology: 100 commercially available products and their scientific evidence. *European radiology*, 31, 3797-3804.
- [16] Verma, S., Choyke, P. L., Eberhardt, S. C., Oto, A., Tempny, C. M., Turkbey, B., & Rosenkrantz, A. B. (2017). The current state of MR imaging–targeted biopsy techniques for detection of prostate cancer. *Radiology*, 285(2), 343-356.
- [17] Weinreb, J. C., Barentsz, J. O., Choyke, P. L., Cornud, F., Haider, M. A., Macura, K. J., ... & Verma, S. (2016). PI-RADS prostate imaging–reporting and data system: 2015, version 2. *European urology*, 69(1), 16-40.
- [18] Weinreb, J. C., Barentsz, J. O., Choyke, P. L., Cornud, F., Haider, M. A., Macura, K. J., ... & Verma, S. (2016). PI-RADS prostate imaging–reporting and data system: 2015, version 2. *European urology*, 69(1), 16-40.
- [19] Westphalen, A. C., McCulloch, C. E., Anaokar, J. M., Arora, S., Barashi, N. S., Barentsz, J. O., ... & Rosenkrantz, A. B. (2020). Variability of the positive predictive value of PI-RADS for prostate MRI across 26 centers: experience of the society of abdominal radiology prostate cancer disease-focused panel. *Radiology*, 296(1), 76-84
- [20] Kumar, A C, Koul J O , Singla , J. M , fazal Ijas , 2023, . Artificial intelligence in disease diagnosis:a systematic literature review. <sup>1</sup>Department of Computer Engineering, Indus Institute of Technology and Engineering, Indus University, Ahmedabad, 382115 India
- [21] Website 1 : [https://www.unite.ai/ar/deep learning](https://www.unite.ai/ar/deep%20learning)
- [22] Websit 2: [What is Hybrid AI? \(analyticsindiamag.com\)](https://www.analyticsindiamag.com/what-is-hybrid-ai/)
- [23] Website 3: [Evorad \(informer.com\)](https://www.evora.ai/)
- [24] Website 4: [3D Slicer image computing platform | 3D Slicer](https://www.3dslicer.org/)
- [25] Website 5: [ماتلاب – المعرفة \(marefa.org\)](https://www.marefa.org/)
- [26] Sawlani, V., Patel, M.D., Davies, N. *et al.* 2020 ,Multiparametric MRI: practical approach and pictorial review of a useful tool in the evaluation of brain tumours and tumour-like lesions. *Insights Imaging*
- [27] Broadhouse, K.M. (2019). The Physics of MRI and How We Use It to Reveal the Mysteries of the Mind. *Front. Young Minds* 7, 23, 1-6. doi: 10.3389/frym.2019.00023.

## الملحق (A) خوارزمية الاقتصاص والدمج

```
t2 = 'D:\the dataset\the selected slices\t2';
adc = 'D:\the dataset\the selected slices\adc';
hbm='D:\the dataset\the selected slices\hbm';
gland='D:\the dataset\the selected slices\gland';
t2f = dir(fullfile(t2, '*.dcm'));
adcf = dir(fullfile(adc, '*.dcm'));
hbmf = dir(fullfile(hbm, '*.dcm'));
glandf = dir(fullfile(gland, '*.dcm'));
j=0;k=0;i=0;
for i = 1:1000
 tfilename = sprintf('p%d\t2.dcm',j,k);
 afilename = sprintf('p%d\adc.dcm',j,k);
 hbmfilename = sprintf('p%d\hbm.dcm',j,k);
 glandfilename = sprintf('p%d\gland.dcm',j,k);
 filepath = fullfile(hbm, hbmfilename);
 if exist(filepath, 'file')
 tfilepath = fullfile(t2, tfilename);
 afilepath = fullfile(adc, afilename);
 hbmfilepath = fullfile(hbm, hbmfilename);
 glandfilepath = fullfile(gland, glandfilename);
 tdicom = dicomread(tfilepath);
 adicom = dicomread(afilepath);
 hbdicom = dicomread(hbmfilepath);
 glandicom = dicomread(glandfilepath);
 [r w]=size(glandicom);
 ad=imresize(adicom,[r w]);
 hb=imresize(hbdicom,[r w]);
 stats = regionprops('table',glandicom,'Centroid');
 center=stats.Centroid;
 y=center(1);x=center(2);
 xmin=x-93;xmax=x+93;ymin=y-93;ymax=y+93;
 roi= [ymin ,xmin,ymax-ymin,xmax-xmin];
 cropt=imcrop(tdicom,roi);
 cropg=imcrop(glandicom,roi);
 cropt=imcrop(ad,roi);
 croph=imcrop(hb,roi);
 t2s=immultiply(cropt,cropg);
 hbvs=immultiply(cropt,croph);
 adcs=immultiply(cropt,cropt);
 outpict = imfuse(t2s,adcs,"falsecolor",'ColorChannels',[1 2 0]);
 out=imfuse(outpict,hbvs,"falsecolor",'ColorChannels',[1 0 2]);
 imshow(out,[])
 imgfilename = sprintf('pimg %d\d.dcm',j,k);
 filepathimg = fullfile('C:\Users\tareq\OneDrive\Desktop\ooo',imgfilename);
 dicomwrite(tt,filepathimg);
 if k==9
 k=-1;j=j+1;
 end
 k=k+1;
 else
 if k==9
 k=-1;j=j+1;
 end
 k=k+1;
 end
end
end
```

## الملحق (B) خوارزمية بناء طبقات شبكة Resnet

```
lgraph = layerGraph();
tempLayers = [
 imageInputLayer([224 224 3], "Name", "input_1")
 convolution2dLayer([7 7], 64, "Name", "conv1", "Padding", [3 3 3 3], "Stride", [2 2])
 batchNormalizationLayer("Name", "bn_conv1", "Epsilon", 0.001)
 reluLayer("Name", "activation_1_relu")
 maxPooling2dLayer([3 3], "Name", "max_pooling2d_1", "Padding", [1 1 1 1], "Stride", [2 2]);
lgraph = addLayers(lgraph, tempLayers);
tempLayers = [
 convolution2dLayer([1 1], 256, "Name", "res2a_branch1", "BiasLearnRateFactor", 0)
 batchNormalizationLayer("Name", "bn2a_branch1", "Epsilon", 0.001)];
lgraph = addLayers(lgraph, tempLayers);
tempLayers = [
 convolution2dLayer([1 1], 64, "Name", "res2a_branch2a", "BiasLearnRateFactor", 0)
 batchNormalizationLayer("Name", "bn2a_branch2a", "Epsilon", 0.001)
 reluLayer("Name", "activation_2_relu")
 convolution2dLayer([3
3], 64, "Name", "res2a_branch2b", "BiasLearnRateFactor", 0, "Padding", "same")
 batchNormalizationLayer("Name", "bn2a_branch2b", "Epsilon", 0.001)
 reluLayer("Name", "activation_3_relu")
 convolution2dLayer([1 1], 256, "Name", "res2a_branch2c", "BiasLearnRateFactor", 0)
 batchNormalizationLayer("Name", "bn2a_branch2c", "Epsilon", 0.001)];
lgraph = addLayers(lgraph, tempLayers);
tempLayers = [
 additionLayer(2, "Name", "add_1")
 reluLayer("Name", "activation_4_relu")];
lgraph = addLayers(lgraph, tempLayers);
tempLayers = [
 convolution2dLayer([1 1], 64, "Name", "res2b_branch2a", "BiasLearnRateFactor", 0)
 batchNormalizationLayer("Name", "bn2b_branch2a", "Epsilon", 0.001)
 reluLayer("Name", "activation_5_relu")
 convolution2dLayer([3
3], 64, "Name", "res2b_branch2b", "BiasLearnRateFactor", 0, "Padding", "same")
 batchNormalizationLayer("Name", "bn2b_branch2b", "Epsilon", 0.001)
 reluLayer("Name", "activation_6_relu")
 convolution2dLayer([1 1], 256, "Name", "res2b_branch2c", "BiasLearnRateFactor", 0)
 batchNormalizationLayer("Name", "bn2b_branch2c", "Epsilon", 0.001)];
lgraph = addLayers(lgraph, tempLayers);
tempLayers = [
 additionLayer(2, "Name", "add_2")
 reluLayer("Name", "activation_7_relu")];
lgraph = addLayers(lgraph, tempLayers);
tempLayers = [
 convolution2dLayer([1 1], 64, "Name", "res2c_branch2a", "BiasLearnRateFactor", 0)
 batchNormalizationLayer("Name", "bn2c_branch2a", "Epsilon", 0.001)
 reluLayer("Name", "activation_8_relu")
 convolution2dLayer([3
3], 64, "Name", "res2c_branch2b", "BiasLearnRateFactor", 0, "Padding", "same")
 batchNormalizationLayer("Name", "bn2c_branch2b", "Epsilon", 0.001)
 reluLayer("Name", "activation_9_relu")
 convolution2dLayer([1 1], 256, "Name", "res2c_branch2c", "BiasLearnRateFactor", 0)
 batchNormalizationLayer("Name", "bn2c_branch2c", "Epsilon", 0.001)];
lgraph = addLayers(lgraph, tempLayers);
tempLayers = [
 additionLayer(2, "Name", "add_3")
 reluLayer("Name", "activation_10_relu")];
lgraph = addLayers(lgraph, tempLayers);
```



```

templayers = [
 convolution2dLayer([1 1],128,"Name","res3a_branch2a","BiasLearnRateFactor",0,"Stride",[2
2])
 batchNormalizationLayer("Name","bn3a_branch2a","Epsilon",0.001)
 reluLayer("Name","activation_11_relu")
 convolution2dLayer([3
3],128,"Name","res3a_branch2b","BiasLearnRateFactor",0,"Padding","same")
 batchNormalizationLayer("Name","bn3a_branch2b","Epsilon",0.001)
 reluLayer("Name","activation_12_relu")
 convolution2dLayer([1 1],512,"Name","res3a_branch2c","BiasLearnRateFactor",0)
 batchNormalizationLayer("Name","bn3a_branch2c","Epsilon",0.001)];
lgraph = addLayers(lgraph,templayers);
templayers = [
 convolution2dLayer([1 1],512,"Name","res3a_branch1","BiasLearnRateFactor",0,"Stride",[2 2])
 batchNormalizationLayer("Name","bn3a_branch1","Epsilon",0.001)];
lgraph = addLayers(lgraph,templayers);
templayers = [
 additionLayer(2,"Name","add_4")
 reluLayer("Name","activation_13_relu")];
lgraph = addLayers(lgraph,templayers);
templayers = [
 convolution2dLayer([1 1],128,"Name","res3b_branch2a","BiasLearnRateFactor",0)
 batchNormalizationLayer("Name","bn3b_branch2a","Epsilon",0.001)
 reluLayer("Name","activation_14_relu")
 convolution2dLayer([3
3],128,"Name","res3b_branch2b","BiasLearnRateFactor",0,"Padding","same")
 batchNormalizationLayer("Name","bn3b_branch2b","Epsilon",0.001)
 reluLayer("Name","activation_15_relu")
 convolution2dLayer([1 1],512,"Name","res3b_branch2c","BiasLearnRateFactor",0)
 batchNormalizationLayer("Name","bn3b_branch2c","Epsilon",0.001)];
lgraph = addLayers(lgraph,templayers);
templayers = [
 additionLayer(2,"Name","add_5")
 reluLayer("Name","activation_16_relu")];
lgraph = addLayers(lgraph,templayers);
templayers = [
 convolution2dLayer([1 1],128,"Name","res3c_branch2a","BiasLearnRateFactor",0)
 batchNormalizationLayer("Name","bn3c_branch2a","Epsilon",0.001)
 reluLayer("Name","activation_17_relu")
 convolution2dLayer([3
3],128,"Name","res3c_branch2b","BiasLearnRateFactor",0,"Padding","same")
 batchNormalizationLayer("Name","bn3c_branch2b","Epsilon",0.001)
 reluLayer("Name","activation_18_relu")
 convolution2dLayer([1 1],512,"Name","res3c_branch2c","BiasLearnRateFactor",0)
 batchNormalizationLayer("Name","bn3c_branch2c","Epsilon",0.001)];
lgraph = addLayers(lgraph,templayers);
templayers = [
 additionLayer(2,"Name","add_6")
 reluLayer("Name","activation_19_relu")];
lgraph = addLayers(lgraph,templayers);
templayers = [
 convolution2dLayer([1 1],128,"Name","res3d_branch2a","BiasLearnRateFactor",0)
 batchNormalizationLayer("Name","bn3d_branch2a","Epsilon",0.001)
 reluLayer("Name","activation_20_relu")
 convolution2dLayer([3
3],128,"Name","res3d_branch2b","BiasLearnRateFactor",0,"Padding","same")
 batchNormalizationLayer("Name","bn3d_branch2b","Epsilon",0.001)
 reluLayer("Name","activation_21_relu")
 convolution2dLayer([1 1],512,"Name","res3d_branch2c","BiasLearnRateFactor",0)
 batchNormalizationLayer("Name","bn3d_branch2c","Epsilon",0.001)];
lgraph = addLayers(lgraph,templayers);

```

```

templayers = [
 additionLayer(2, "Name", "add_7")
 reluLayer("Name", "activation_22_relu")];
lgraph = addLayers(lgraph, templayers);
templayers = [
 convolution2dLayer([1 1], 256, "Name", "res4a_branch2a", "BiasLearnRateFactor", 0, "Stride", [2
2])
 batchNormalizationLayer("Name", "bn4a_branch2a", "Epsilon", 0.001)
 reluLayer("Name", "activation_23_relu")
 convolution2dLayer([3
3], 256, "Name", "res4a_branch2b", "BiasLearnRateFactor", 0, "Padding", "same")
 batchNormalizationLayer("Name", "bn4a_branch2b", "Epsilon", 0.001)
 reluLayer("Name", "activation_24_relu")
 convolution2dLayer([1 1], 1024, "Name", "res4a_branch2c", "BiasLearnRateFactor", 0)
 batchNormalizationLayer("Name", "bn4a_branch2c", "Epsilon", 0.001)];
lgraph = addLayers(lgraph, templayers);
templayers = [
 convolution2dLayer([1 1], 1024, "Name", "res4a_branch1", "BiasLearnRateFactor", 0, "Stride", [2
2])
 batchNormalizationLayer("Name", "bn4a_branch1", "Epsilon", 0.001)];
lgraph = addLayers(lgraph, templayers);
templayers = [
 additionLayer(2, "Name", "add_8")
 reluLayer("Name", "activation_25_relu")];
lgraph = addLayers(lgraph, templayers);
templayers = [
 convolution2dLayer([1 1], 256, "Name", "res4b_branch2a", "BiasLearnRateFactor", 0)
 batchNormalizationLayer("Name", "bn4b_branch2a", "Epsilon", 0.001)
 reluLayer("Name", "activation_26_relu")
 convolution2dLayer([3
3], 256, "Name", "res4b_branch2b", "BiasLearnRateFactor", 0, "Padding", "same")
 batchNormalizationLayer("Name", "bn4b_branch2b", "Epsilon", 0.001)
 reluLayer("Name", "activation_27_relu")
 convolution2dLayer([1 1], 1024, "Name", "res4b_branch2c", "BiasLearnRateFactor", 0)
 batchNormalizationLayer("Name", "bn4b_branch2c", "Epsilon", 0.001)];
lgraph = addLayers(lgraph, templayers);
templayers = [
 additionLayer(2, "Name", "add_9")
 reluLayer("Name", "activation_28_relu")];
lgraph = addLayers(lgraph, templayers);
templayers = [
 convolution2dLayer([1 1], 256, "Name", "res4c_branch2a", "BiasLearnRateFactor", 0)
 batchNormalizationLayer("Name", "bn4c_branch2a", "Epsilon", 0.001)
 reluLayer("Name", "activation_29_relu")
 convolution2dLayer([3
3], 256, "Name", "res4c_branch2b", "BiasLearnRateFactor", 0, "Padding", "same")
 batchNormalizationLayer("Name", "bn4c_branch2b", "Epsilon", 0.001)
 reluLayer("Name", "activation_30_relu")
 convolution2dLayer([1 1], 1024, "Name", "res4c_branch2c", "BiasLearnRateFactor", 0)
 batchNormalizationLayer("Name", "bn4c_branch2c", "Epsilon", 0.001)];
lgraph = addLayers(lgraph, templayers);
templayers = [
 additionLayer(2, "Name", "add_10")
 reluLayer("Name", "activation_31_relu")];
lgraph = addLayers(lgraph, templayers);
templayers = [
 convolution2dLayer([1 1], 256, "Name", "res4d_branch2a", "BiasLearnRateFactor", 0)
 batchNormalizationLayer("Name", "bn4d_branch2a", "Epsilon", 0.001)
 reluLayer("Name", "activation_32_relu")
 convolution2dLayer([3
3], 256, "Name", "res4d_branch2b", "BiasLearnRateFactor", 0, "Padding", "same")

```

```

batchNormalizationLayer("Name", "bn4d_branch2b", "Epsilon", 0.001)
reluLayer("Name", "activation_33_relu")
convolution2dLayer([1 1], 1024, "Name", "res4d_branch2c", "BiasLearnRateFactor", 0)
batchNormalizationLayer("Name", "bn4d_branch2c", "Epsilon", 0.001)];
lgraph = addLayers(lgraph, tempLayers);
tempLayers = [
 additionLayer(2, "Name", "add_11")
 reluLayer("Name", "activation_34_relu")];
lgraph = addLayers(lgraph, tempLayers);
tempLayers = [
 convolution2dLayer([1 1], 256, "Name", "res4e_branch2a", "BiasLearnRateFactor", 0)
 batchNormalizationLayer("Name", "bn4e_branch2a", "Epsilon", 0.001)
 reluLayer("Name", "activation_35_relu")
 convolution2dLayer([3
3], 256, "Name", "res4e_branch2b", "BiasLearnRateFactor", 0, "Padding", "same")
 batchNormalizationLayer("Name", "bn4e_branch2b", "Epsilon", 0.001)
 reluLayer("Name", "activation_36_relu")
 convolution2dLayer([1 1], 1024, "Name", "res4e_branch2c", "BiasLearnRateFactor", 0)
 batchNormalizationLayer("Name", "bn4e_branch2c", "Epsilon", 0.001)];
lgraph = addLayers(lgraph, tempLayers);
tempLayers = [
 additionLayer(2, "Name", "add_12")
 reluLayer("Name", "activation_37_relu")];
lgraph = addLayers(lgraph, tempLayers);
tempLayers = [
 convolution2dLayer([1 1], 256, "Name", "res4f_branch2a", "BiasLearnRateFactor", 0)
 batchNormalizationLayer("Name", "bn4f_branch2a", "Epsilon", 0.001)
 reluLayer("Name", "activation_38_relu")
 convolution2dLayer([3
3], 256, "Name", "res4f_branch2b", "BiasLearnRateFactor", 0, "Padding", "same")
 batchNormalizationLayer("Name", "bn4f_branch2b", "Epsilon", 0.001)
 reluLayer("Name", "activation_39_relu")
 convolution2dLayer([1 1], 1024, "Name", "res4f_branch2c", "BiasLearnRateFactor", 0)
 batchNormalizationLayer("Name", "bn4f_branch2c", "Epsilon", 0.001)];
lgraph = addLayers(lgraph, tempLayers);
tempLayers = [
 additionLayer(2, "Name", "add_13")
 reluLayer("Name", "activation_40_relu")];
lgraph = addLayers(lgraph, tempLayers);
tempLayers = [
 convolution2dLayer([1 1], 512, "Name", "res5a_branch2a", "BiasLearnRateFactor", 0, "Stride", [2
2])
 batchNormalizationLayer("Name", "bn5a_branch2a", "Epsilon", 0.001)
 reluLayer("Name", "activation_41_relu")
 convolution2dLayer([3
3], 512, "Name", "res5a_branch2b", "BiasLearnRateFactor", 0, "Padding", "same")
 batchNormalizationLayer("Name", "bn5a_branch2b", "Epsilon", 0.001)
 reluLayer("Name", "activation_42_relu")
 convolution2dLayer([1 1], 2048, "Name", "res5a_branch2c", "BiasLearnRateFactor", 0)
 batchNormalizationLayer("Name", "bn5a_branch2c", "Epsilon", 0.001)];
lgraph = addLayers(lgraph, tempLayers);
tempLayers = [
 convolution2dLayer([1 1], 2048, "Name", "res5a_branch1", "BiasLearnRateFactor", 0, "Stride", [2
2])
 batchNormalizationLayer("Name", "bn5a_branch1", "Epsilon", 0.001)];
lgraph = addLayers(lgraph, tempLayers);
tempLayers = [
 additionLayer(2, "Name", "add_14")
 reluLayer("Name", "activation_43_relu")];
lgraph = addLayers(lgraph, tempLayers);
tempLayers = [

```

```

convolution2dLayer([1 1],512,"Name","res5b_branch2a","BiasLearnRateFactor",0)
batchNormalizationLayer("Name","bn5b_branch2a","Epsilon",0.001)
reluLayer("Name","activation_44_relu")
convolution2dLayer([3
3],512,"Name","res5b_branch2b","BiasLearnRateFactor",0,"Padding","same")
batchNormalizationLayer("Name","bn5b_branch2b","Epsilon",0.001)
reluLayer("Name","activation_45_relu")
convolution2dLayer([1 1],2048,"Name","res5b_branch2c","BiasLearnRateFactor",0)
batchNormalizationLayer("Name","bn5b_branch2c","Epsilon",0.001)];
lgraph = addLayers(lgraph,templayers);
templayers = [
 additionLayer(2,"Name","add_15")
 reluLayer("Name","activation_46_relu")];
lgraph = addLayers(lgraph,templayers);
templayers = [
 convolution2dLayer([1 1],512,"Name","res5c_branch2a","BiasLearnRateFactor",0)
 batchNormalizationLayer("Name","bn5c_branch2a","Epsilon",0.001)
 reluLayer("Name","activation_47_relu")
 convolution2dLayer([3
3],512,"Name","res5c_branch2b","BiasLearnRateFactor",0,"Padding","same")
 batchNormalizationLayer("Name","bn5c_branch2b","Epsilon",0.001)
 reluLayer("Name","activation_48_relu")
 convolution2dLayer([1 1],2048,"Name","res5c_branch2c","BiasLearnRateFactor",0)
 batchNormalizationLayer("Name","bn5c_branch2c","Epsilon",0.001)];
lgraph = addLayers(lgraph,templayers);

templayers = [
 additionLayer(2,"Name","add_16")
 reluLayer("Name","activation_49_relu")
 globalAveragePooling2dLayer("Name","avg_pool")
 fullyConnectedLayer(1000,"Name","fc1000","BiasLearnRateFactor",0)
 sigmoidLayer("Name","fc1000 ")
 classificationLayer("Name","ClassificationLayer_fc1000")];
lgraph = addLayers(lgraph,templayers);
[imdsTrain,imdsTest] = splitEachLabel(imgt,120,'randomize');
options = trainingOptions('sgdm','MaxEpochs',140,'InitialLearnRate',0.001,'Verbose',false,
'Plots','training-
progress','plots','LearnRateSchedule','piecewise','LearnRateDropFactor',0.001,'validationdata',
valid);
%% Connect Layer Branches
% Connect all the branches of the network to create the network graph.
lgraph = connectLayers(lgraph,"max_pooling2d_1","res2a_branch1");
lgraph = connectLayers(lgraph,"max_pooling2d_1","res2a_branch2a");
lgraph = connectLayers(lgraph,"bn2a_branch1","add_1/in2");
lgraph = connectLayers(lgraph,"bn2a_branch2c","add_1/in1");
lgraph = connectLayers(lgraph,"activation_4_relu","res2b_branch2a");
lgraph = connectLayers(lgraph,"activation_4_relu","add_2/in2");
lgraph = connectLayers(lgraph,"bn2b_branch2c","add_2/in1");
lgraph = connectLayers(lgraph,"activation_7_relu","res2c_branch2a");
lgraph = connectLayers(lgraph,"activation_7_relu","add_3/in2");
lgraph = connectLayers(lgraph,"bn2c_branch2c","add_3/in1");
lgraph = connectLayers(lgraph,"activation_10_relu","res3a_branch2a");
lgraph = connectLayers(lgraph,"activation_10_relu","res3a_branch1");
lgraph = connectLayers(lgraph,"bn3a_branch1","add_4/in2");
lgraph = connectLayers(lgraph,"bn3a_branch2c","add_4/in1");
lgraph = connectLayers(lgraph,"activation_13_relu","res3b_branch2a");
lgraph = connectLayers(lgraph,"activation_13_relu","add_5/in2");
lgraph = connectLayers(lgraph,"bn3b_branch2c","add_5/in1");
lgraph = connectLayers(lgraph,"activation_16_relu","res3c_branch2a");
lgraph = connectLayers(lgraph,"activation_16_relu","add_6/in2");
lgraph = connectLayers(lgraph,"bn3c_branch2c","add_6/in1");

```



```
lgraph = connectLayers(lgraph,"activation_19_relu","res3d_branch2a");
lgraph = connectLayers(lgraph,"activation_19_relu","add_7/in2");
lgraph = connectLayers(lgraph,"bn3d_branch2c","add_7/in1");
lgraph = connectLayers(lgraph,"activation_22_relu","res4a_branch2a");
lgraph = connectLayers(lgraph,"activation_22_relu","res4a_branch1");
lgraph = connectLayers(lgraph,"bn4a_branch1","add_8/in2");
lgraph = connectLayers(lgraph,"bn4a_branch2c","add_8/in1");
lgraph = connectLayers(lgraph,"activation_25_relu","res4b_branch2a");
lgraph = connectLayers(lgraph,"activation_25_relu","add_9/in2");
lgraph = connectLayers(lgraph,"bn4b_branch2c","add_9/in1");
lgraph = connectLayers(lgraph,"activation_28_relu","res4c_branch2a");
lgraph = connectLayers(lgraph,"activation_28_relu","add_10/in2");
lgraph = connectLayers(lgraph,"bn4c_branch2c","add_10/in1");
lgraph = connectLayers(lgraph,"activation_31_relu","res4d_branch2a");
lgraph = connectLayers(lgraph,"activation_31_relu","add_11/in2");
lgraph = connectLayers(lgraph,"bn4d_branch2c","add_11/in1");
lgraph = connectLayers(lgraph,"activation_34_relu","res4e_branch2a");
lgraph = connectLayers(lgraph,"activation_34_relu","add_12/in2");
lgraph = connectLayers(lgraph,"bn4e_branch2c","add_12/in1");
lgraph = connectLayers(lgraph,"activation_37_relu","res4f_branch2a");
lgraph = connectLayers(lgraph,"activation_37_relu","add_13/in2");
lgraph = connectLayers(lgraph,"bn4f_branch2c","add_13/in1");
lgraph = connectLayers(lgraph,"activation_40_relu","res5a_branch2a");
lgraph = connectLayers(lgraph,"activation_40_relu","res5a_branch1");
lgraph = connectLayers(lgraph,"bn5a_branch1","add_14/in2");
lgraph = connectLayers(lgraph,"bn5a_branch2c","add_14/in1");
lgraph = connectLayers(lgraph,"activation_43_relu","res5b_branch2a");
lgraph = connectLayers(lgraph,"activation_43_relu","add_15/in2");
lgraph = connectLayers(lgraph,"bn5b_branch2c","add_15/in1");
lgraph = connectLayers(lgraph,"activation_46_relu","res5c_branch2a");
lgraph = connectLayers(lgraph,"activation_46_relu","add_16/in2");
lgraph = connectLayers(lgraph,"bn5c_branch2c","add_16/in1");
networkmodel_1=trainNetwork(imdsTrain,lgraph,options);
x = linspace(0, 140, 140);
plot(x,trainInfoStruct_1.tr)
```

## الملحق (C) حساب اداء النظم

```
TP=0; TN=0; FP=0; FN = 0;
for o = 1:100
 prcancer = matrix (o , 1)
 truecancer = matrix (o , 2)
 if prcancer>0.5 && truecancer == 1
 TP = TP + 1
 elseif prcancer<0.5 && truecancer == 0
 TN = TN + 1
 elseif prcancer>0.5 && truecancer == 0
 FP = FP + 1
 elseif prcancer <0.5 && truecancer == 1
 FN = FN + 1
 end
end
Accuracy=(TP+TN)/(TP+TN+FP+FN)

Sensitivity= (TP)/(TP+FN)
Specificity=TN/(TN+FP)
```

## الملحق (D) معالجة البيانات التوصيفيه

```
imgs="C:\Users\tareq\OneDrive\Desktop\testo";
imgt = dir(fullfile(imgs, '*.png'));
datasheet = xlsread('C:\Users\tareq\OneDrive\Desktop\marksheet 2.csv');
data=num2str(datasheet(:,1));
patient_age=datasheet(:,3);
psa=datasheet(:,4);
prostat_volume=datasheet(:,6);
caseofprostate=datasheet(:,11)
psad=datasheet(:,5)
caseisup=datasheet(:,10);
[m, n]=size(imgt);
matrix=zeros(m,7);
j=1;k=1;
for i=1:2000
 t=imgt(j).name;
 tt="C:\Users\tareq\OneDrive\Desktop\testo\"+t;
 t1=imread(tt);
 output=predict(trainedNetwork_1,t1);
 outb=output(:,1);
 outc=output(:,2);
 o=t(6:8);
 dd=datasheet(k,1);
 dd=num2str(dd);
 frst=dd(:,4);
 scnd=dd(:,5);
 hund=dd(:,3);
 datanum=[hund frst scnd];
 datanum2=str2num(datanum)
 if o== datanum
 matrix(j,2)=outc;
 matrix(j,3)=patient_age(k,1);
 matrix(j,4)=psa(k,1);
 matrix(j,5)=prostat_volume(k,1);
 matrix(j,6)=psad(k,1);
 matrix(j,7)=caseofprostate(k,1);
 j=j+1;
 k=k+1
 else
 matrix(j,:)=0;
 k=k+1;
 end
end
end
```



## الملحق (E) خوارزمية بناء الواجهة الرسومية

```
classdef prostate0diagnose < matlab.apps.AppBase
% Properties that correspond to app components
properties (Access = public)
UIFigure matlab.ui.Figure
PatientConditionButton matlab.ui.control.Button
PatientConditionEditField matlab.ui.control.EditField
PSAEditField matlab.ui.control.NumericEditField
PSAEditFieldLabel matlab.ui.control.Label
PSAEditField matlab.ui.control.NumericEditField
PSAEditFieldLabel matlab.ui.control.Label
ProstateVolumeEditField matlab.ui.control.NumericEditField
ProstateVolumeEditFieldLabel matlab.ui.control.Label
patientAgeEditField matlab.ui.control.NumericEditField
patientAgeEditFieldLabel matlab.ui.control.Label
ProcessTheImagesButton matlab.ui.control.Button
LoadMaskButton matlab.ui.control.Button
LoadADCButton matlab.ui.control.Button
LoadDWIButton matlab.ui.control.Button
LoadT2Button matlab.ui.control.Button
UIAxes matlab.ui.control.UIAxes
UIAxes2_2 matlab.ui.control.UIAxes
UIAxes3_2 matlab.ui.control.UIAxes
UIAxes3 matlab.ui.control.UIAxes
UIAxes2 matlab.ui.control.UIAxes
end
properties (Access = public)
imgort2=0;
imgordwi=0;
imgoradc=0;
imgorgland=0;
output=0
end
% Callbacks that handle component events
methods (Access = private)
% Button pushed function: LoadT2Button
function LoadT2ButtonPushed(app, event)
[fn1, pn1] = uigetfile({'*.dcm'}, 'select dicom file');
complete1 = strcat(pn1,fn1);
app.imgort2= dicomread(complete1);
imshow(app.imgort2,[], 'parent',app.UIAxes2);
end
% Button pushed function: LoadDWIButton
function LoadDWIButtonPushed(app, event)
[fn2, pn2] = uigetfile({'*.dcm'}, 'select dicom file');
complete2 = strcat(pn2,fn2);
app.imgordwi= dicomread(complete2);
imshow(app.imgordwi,[], 'parent',app.UIAxes3);
end
% Button pushed function: LoadADCButton
function LoadADCButtonPushed(app, event)
[fn3, pn3] = uigetfile({'*.dcm'}, 'select dicom file');
complete3 = strcat(pn3,fn3);
```

```

app.imgoradc= dicomread(complete3);
imshow(app.imgoradc,[],'parent',app.UIAxes3_2);
end
% Button pushed function: LoadMaskButton
function LoadMaskButtonPushed(app, event)
[fn4, pn4] = uigetfile({'*.dcm'},'select dicom file');
complete4 = strcat(pn4,fn4);
app.imgorgland= dicomread(complete4);
imshow(app.imgorgland,[],'parent',app.UIAxes2_2);
end
% Button pushed function: ProcesstheImagesButton
function ProcesstheImagesButtonPushed(app, event)
[out,app.output]= fun(app.imgort2,app.imgordwi,app.imgoradc,app.imgorgland);
imshow(out,[],'parent',app.UIAxes);
end
% Value changed function: patientAgeEditField
function patientAgeEditFieldValueChanged(app, event)
value = app.patientAgeEditField.Value;
end
% Value changed function: PSAEditField
function PSAEditFieldValueChanged(app, event)
value = app.PSAEditField.Value;
end
% Value changed function: ProstateVolumeEditField
function ProstateVolumeEditFieldValueChanged(app, event)
value= app.ProstateVolumeEditField.Value;
end
% Value changed function: PSAEditField
function PSAEditFieldValueChanged(app, event)
value = app.PSAEditField.Value;
end
% Callback function
function PatientConditionTextAreaValueChanged(app, event)
t=[app.output,valueage,valuepsa,valuepros,valuepsad];
out2 = boostedtreesres2.predictFcn(t)
app.feedbackTextArea.value=out2
end
% Button pushed function: PatientConditionButton
function PatientConditionButtonPushed(app, event)
outt= app.output
valueage=app.patientAgeEditField.Value
valuepsa=app.PSAEditField.Value;
valuepros=app.ProstateVolumeEditField.Value;
valuepsad=app.PSAEditField.Value
% t=[outt,valueage,valuepsa,valuepros,valuepsad]
[v]=block2(app.output,valueage,valuepsa,valuepros,valuepsad)
app.PatientConditionButton.value=v
end
% Callback function
function predictDeepLearningButtonPushed(app, event)
out=app.ProcesstheImagesButton.Parent
end
end
% Component initialization
methods (Access = private)

```

```
% Create UIFigure and components
function createComponents(app)
% Create UIFigure and hide until all components are created
app.UIFigure = uifigure('Visible', 'off');
app.UIFigure.Position = [100 100 1510 632];
app.UIFigure.Name = 'MATLAB App';
% Create UIAxes2
app.UIAxes2 = uiaxes(app.UIFigure);
title(app.UIAxes2, 'T2')
app.UIAxes2.FontSize = 6;
app.UIAxes2.Position = [148 420 342 201];
% Create UIAxes3
app.UIAxes3 = uiaxes(app.UIFigure);
title(app.UIAxes3, 'DWI')
app.UIAxes3.FontSize = 6;
app.UIAxes3.Position = [148 220 342 201];
% Create UIAxes3_2
app.UIAxes3_2 = uiaxes(app.UIFigure);
title(app.UIAxes3_2, 'ADC')
app.UIAxes3_2.FontSize = 6;
app.UIAxes3_2.Position = [148 9 342 212];
% Create UIAxes2_2
app.UIAxes2_2 = uiaxes(app.UIFigure);
title(app.UIAxes2_2, 'Mask')
app.UIAxes2_2.FontSize = 6;
app.UIAxes2_2.Position = [679 419 342 201];
% Create UIAxes
app.UIAxes = uiaxes(app.UIFigure);
title(app.UIAxes, 'colored image')
app.UIAxes.FontSize = 6;
app.UIAxes.Position = [611 8 476 302];
% Create LoadT2Button
app.LoadT2Button = uibutton(app.UIFigure, 'push');
app.LoadT2Button.ButtonPushedFcn = createCallbackFcn(app, @LoadT2ButtonPushed, true);
app.LoadT2Button.Tag = 'imgort2';
app.LoadT2Button.FontSize = 18;
app.LoadT2Button.Position = [12 495 137 50];
app.LoadT2Button.Text = 'Load T2';
% Create LoadDWIButton
app.LoadDWIButton = uibutton(app.UIFigure, 'push');
app.LoadDWIButton.ButtonPushedFcn = createCallbackFcn(app, @LoadDWIButtonPushed, true);
app.LoadDWIButton.FontSize = 18;
app.LoadDWIButton.Position = [12 280 137 53];
app.LoadDWIButton.Text = 'Load DWI';
% Create LoadADCButton
app.LoadADCButton = uibutton(app.UIFigure, 'push');
app.LoadADCButton.ButtonPushedFcn = createCallbackFcn(app, @LoadADCButtonPushed, true);
app.LoadADCButton.FontSize = 18;
app.LoadADCButton.Position = [12 77 137 51];
app.LoadADCButton.Text = 'Load ADC';
% Create LoadMaskButton
app.LoadMaskButton = uibutton(app.UIFigure, 'push');
app.LoadMaskButton.ButtonPushedFcn = createCallbackFcn(app, @LoadMaskButtonPushed, true);
app.LoadMaskButton.FontSize = 18;
app.LoadMaskButton.Position = [525 494 137 51];
app.LoadMaskButton.Text = 'Load Mask';
```

```
% Create ProcesstheImagesButton
app.ProcesstheImagesButton = uibutton(app.UIFigure, 'push');
app.ProcesstheImagesButton.ButtonPushedFcn = createCallbackFcn(app,
@ProcesstheImagesButtonPushed, true);
app.ProcesstheImagesButton.FontSize = 20;
app.ProcesstheImagesButton.Position = [731 331 238 49];
app.ProcesstheImagesButton.Text = 'Process the Images';
% Create patientAgeEditFieldLabel
app.patientAgeEditFieldLabel = uilabel(app.UIFigure);
app.patientAgeEditFieldLabel.HorizontalAlignment = 'right';
app.patientAgeEditFieldLabel.FontSize = 16;
app.patientAgeEditFieldLabel.FontWeight = 'bold';
app.patientAgeEditFieldLabel.Position = [1143 508 92 22];
app.patientAgeEditFieldLabel.Text = 'patient Age';
% Create patientAgeEditField
app.patientAgeEditField = uieditfield(app.UIFigure, 'numeric');
app.patientAgeEditField.ValueChangedFcn = createCallbackFcn(app,
@patientAgeEditFieldValueChanged, true);
app.patientAgeEditField.HorizontalAlignment = 'center';
app.patientAgeEditField.FontSize = 16;
app.patientAgeEditField.FontWeight = 'bold';
app.patientAgeEditField.Position = [1250 508 199 22];
% Create ProstateVolumeEditFieldLabel
app.ProstateVolumeEditFieldLabel = uilabel(app.UIFigure);
app.ProstateVolumeEditFieldLabel.HorizontalAlignment = 'right';
app.ProstateVolumeEditFieldLabel.FontSize = 16;
app.ProstateVolumeEditFieldLabel.FontWeight = 'bold';
app.ProstateVolumeEditFieldLabel.Position = [1104 412 131 22];
app.ProstateVolumeEditFieldLabel.Text = 'Prostate Volume';
% Create ProstateVolumeEditField
app.ProstateVolumeEditField = uieditfield(app.UIFigure, 'numeric');
app.ProstateVolumeEditField.ValueChangedFcn = createCallbackFcn(app,
@ProstateVolumeEditFieldValueChanged, true);
app.ProstateVolumeEditField.HorizontalAlignment = 'center';
app.ProstateVolumeEditField.FontSize = 16;
app.ProstateVolumeEditField.FontWeight = 'bold';
app.ProstateVolumeEditField.Position = [1250 412 199 22];
% Create PSAEditFieldLabel
app.PSAEditFieldLabel = uilabel(app.UIFigure);
app.PSAEditFieldLabel.HorizontalAlignment = 'right';
app.PSAEditFieldLabel.FontSize = 16;
app.PSAEditFieldLabel.FontWeight = 'bold';
app.PSAEditFieldLabel.Position = [1185 358 50 22];
app.PSAEditFieldLabel.Text = 'PSAD';

% Create PSAEditField
app.PSAEditField = uieditfield(app.UIFigure, 'numeric');
app.PSAEditField.ValueChangedFcn = createCallbackFcn(app, @PSAEditFieldValueChanged, true);
app.PSAEditField.HorizontalAlignment = 'center';
app.PSAEditField.FontSize = 16;
app.PSAEditField.FontWeight = 'bold';
app.PSAEditField.Position = [1250 358 199 22];
 % Create PSAEditFieldLabel
 app.PSAEditFieldLabel = uilabel(app.UIFigure);
 app.PSAEditFieldLabel.HorizontalAlignment = 'right';
```

```

app.PSAEditFieldLabel.FontSize = 16;
app.PSAEditFieldLabel.FontWeight = 'bold';
app.PSAEditFieldLabel.Position = [1197 459 38 22];
app.PSAEditFieldLabel.Text = 'PSA';
% Create PSAEditField
app.PSAEditField = uieditfield(app.UIFigure, 'numeric');
app.PSAEditField.ValueChangedFcn = createCallbackFcn(app,
@PSAEditFieldValueChanged, true);
app.PSAEditField.HorizontalAlignment = 'center';
app.PSAEditField.FontSize = 16;
app.PSAEditField.FontWeight = 'bold';
app.PSAEditField.Position = [1250 459 199 22];
% Create PatientConditionEditField
app.PatientConditionEditField = uieditfield(app.UIFigure, 'text');
app.PatientConditionEditField.Position = [1201 126 248 116];
% Create PatientConditionButton
app.PatientConditionButton = uibutton(app.UIFigure, 'push');
app.PatientConditionButton.ButtonPushedFcn = createCallbackFcn(app,
@PatientConditionButtonPushed, true);
app.PatientConditionButton.FontSize = 22;
app.PatientConditionButton.FontWeight = 'bold';
app.PatientConditionButton.FontAngle = 'italic';
app.PatientConditionButton.Position = [1250 66 199 46];
app.PatientConditionButton.Text = 'Patient Condition';
% Show the figure after all components are created
app.UIFigure.Visible = 'on';
end
end
% App creation and deletion
methods (Access = public)
% Construct app
function app = prostate0diagnose
% Create UIFigure and components
createComponents(app)
% Register the app with App Designer
registerApp(app, app.UIFigure)
if nargin == 0
clear app
end
end
% Code that executes before app deletion
function delete(app)
% Delete UIFigure when app is deleted
delete(app.UIFigure)
end
end
end
end

```

**Ministry of Higher education and research**  
**Al-Andalus University for medical sciences**  
**Faculty of Biomedical Engineering**

---

## ***Diagnosis of prostate cancer using MRI***

---

**Graduation project prepared to obtain a bachelor's degree in /**  
**/medical engineering**

**Prepared by:**

**Basel Kaddor**

**Zeinab Makhlof**

**Tareq Zaefa**

**Supervised by**

**DR MOHAMAD DAER**

**YEAR**

**2024 –2023**

**GP24INF14**